A.0 Data Loading & Cleaning

A.0.1 Load the ENO dataset

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
from IPython.display import display

eno_cols = [
    "ENO",
    "anho_notificacion",
    "region",
    "codigo_comuna_residencia",
    "nacionalidad",
    "sexo",
    "grupo_edad",
    "nombre_instruccion",
    "cie_10_diagnostico",
    "diagnostico",
    "pais_contagio"
]

eno = pd.read_csv(

"/Users/ignaciorodriguezperez/Desktop/Preparacion_datos/20241218_base_
eno_final.csv",
    sep=";",
    encoding="utf-8-sig",
    usecols=eno_cols
)

print("Shape ENO:", eno.shape)
print("\nInfo ENO:")
print(eno.info())
```

```
Shape ENO: (333300, 11)

Info ENO:
<class 'pandas.DataFrame'>
RangeIndex: 333300 entries, 0 to 333299
Data columns (total 11 columns):
 #   Column                    Non-Null Count   Dtype
---  ------                    --------------   -----
 0   region                    333300 non-null  str
 1   nacionalidad              333300 non-null  str
 2   cie_10_diagnostico        333300 non-null  str
 3   diagnostico               333300 non-null  str
 4   anho_notificacion         333300 non-null  int64
 5   ENO                       333300 non-null  str
```

```
 6   nombre_instruccion        333300 non-null  str
 7   pais_contagio             333300 non-null  str
 8   sexo                      333300 non-null  str
 9   grupo_edad                333300 non-null  str
 10  codigo_comuna_residencia  333300 non-null  str
dtypes: int64(1), str(10)
memory usage: 65.4 MB
None
```

A.0.2 Filter the comunas

```
MY_COMUNAS = [13102, 13105, 13302]  # Cerrillos, Estación Central,
Lampa

my_comunas_str = [str(c) for c in MY_COMUNAS]

eno_com =
eno[eno["codigo_comuna_residencia"].isin(my_comunas_str)].copy()

print(f"\nRows in my comunas: {len(eno_com):,}")

# Filas anonimizadas en TODO el dataset
anon_rows = (eno["codigo_comuna_residencia"] == "*****").sum()
anon_pct = anon_rows / len(eno) * 100

print(f"Rows anonymized in full ENO dataset: {anon_rows:,}")
print(f"Percent anonymized in full ENO dataset: {anon_pct:.2f}%")
```

```
Rows in my comunas: 2,526
Rows anonymized in full ENO dataset: 148,217
Percent anonymized in full ENO dataset: 44.47%
```

A.0.3 Clean the nationality variable

```
# Distribución de nacionalidad en las comunas filtradas
nat_dist =
eno_com["nacionalidad"].value_counts(dropna=False).reset_index()
nat_dist.columns = ["nacionalidad", "count"]
nat_dist["pct"] = nat_dist["count"] / len(eno_com) * 100

print("Distribution of nacionalidad in filtered ENO data:")
print(nat_dist)

# Cantidad de filas "Desconocido"
n_desconocido = (eno_com["nacionalidad"] == "Desconocido").sum()
pct_desconocido = n_desconocido / len(eno_com) * 100

print(f"\nRows with nacionalidad == 'Desconocido': {n_desconocido:,}")
print(f"Percent of filtered ENO data: {pct_desconocido:.2f}%")
```

```python
# Base para análisis por nacionalidad: excluir 'Desconocido'
eno_com_nat = eno_com[eno_com["nacionalidad"] != "Desconocido"].copy()

print(f"\nRows kept for nationality-specific analyses:
{len(eno_com_nat):,}")
print(f"Rows dropped for nationality-specific analyses:
{n_desconocido:,}")
```

```
Distribution of nacionalidad in filtered ENO data:
  nacionalidad  count        pct
0        Chile   1321  52.296120
1  Desconocido    900  35.629454
2   Extranjero    305  12.074426

Rows with nacionalidad == 'Desconocido': 900
Percent of filtered ENO data: 35.63%

Rows kept for nationality-specific analyses: 1,626
Rows dropped for nationality-specific analyses: 900
```

```python
# Ordenar de mayor a menor
nat_dist_sorted = nat_dist.sort_values(by="count", ascending=True)

plt.figure(figsize=(8,5))

plt.barh(
    nat_dist_sorted["nacionalidad"],
    nat_dist_sorted["count"]
)

plt.xlabel("Number of notifications")
plt.ylabel("Nationality")
plt.title("Distribution of Nationality in ENO (My Comunas)")

# Agregar etiquetas de porcentaje
for i, (count, pct) in enumerate(zip(nat_dist_sorted["count"],
nat_dist_sorted["pct"])):
    plt.text(count, i, f" {pct:.1f}%", va='center')

plt.tight_layout()
plt.show()
```

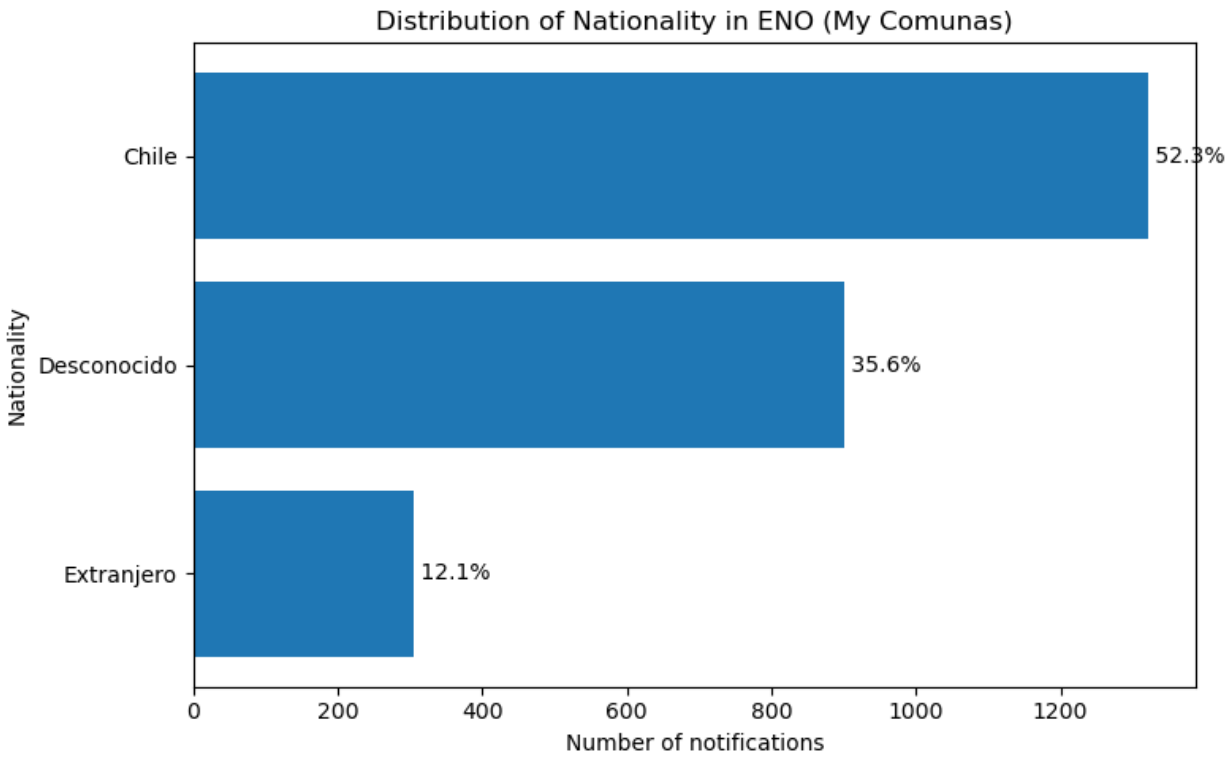

A.0.4 Report the time span

```
# Asegurar que el año sea numérico
eno_com["anho_notificacion"] =
pd.to_numeric(eno_com["anho_notificacion"], errors="coerce")

# Rango de años
year_min = eno_com["anho_notificacion"].min()
year_max = eno_com["anho_notificacion"].max()

print(f"Time span in filtered ENO data: {int(year_min)} -
{int(year_max)}")

# Notificaciones por año
eno_yearly = (
    eno_com["anho_notificacion"]
    .value_counts()
    .sort_index()
    .reset_index()
)

eno_yearly.columns = ["year", "notifications"]

print("\nNotifications per year:")
print(eno_yearly)
```

```
Time span in filtered ENO data: 2007 - 2024

Notifications per year:
    year  notifications
0   2007             85
1   2008             69
2   2009             94
3   2010             78
4   2011            108
5   2012             92
6   2013            104
7   2014             96
8   2015            140
9   2016             84
10  2017            111
11  2018            256
12  2019            191
13  2020            133
14  2021            103
15  2022            156
16  2023            420
17  2024            206
```

Análisis de Carga y Limpieza de Datos (ENO)

Al cargar el dataset original, este cuenta con **333.300 registros** a nivel nacional. Luego de filtrar por nuestras comunas asignadas (Cerrillos, Estación Central y Lampa), nos quedamos con **2.526 notificaciones**.

Es importante destacar que en el dataset completo existe un **44.47% de registros anonimizados** (con el valor `*****` en el código de comuna), lo que significa que estamos perdiendo un volumen considerable de datos espaciales.

Respecto a la nacionalidad en nuestra muestra, un **52.3%** corresponde a chilenos, un **12.1%** a extranjeros y un **35.6%** a nacionalidad "Desconocida". Dado el alto volumen de datos faltantes en esta variable, se decidió excluir los 900 casos "Desconocidos" para los futuros análisis específicos de nacionalidad, conservando una base limpia de **1.626 registros**.

A.1 Notification Trends Over Time

A.1.1 Overall trend

```
plt.figure(figsize=(10,5))
plt.plot(
    eno_yearly["year"],
    eno_yearly["notifications"],
    marker='o'
)
```

```
plt.xlabel("Year")
plt.ylabel("Number of notifications")
plt.title("ENO Notifications Over Time (My Comunas)")

plt.grid()

plt.tight_layout()
plt.show()
```

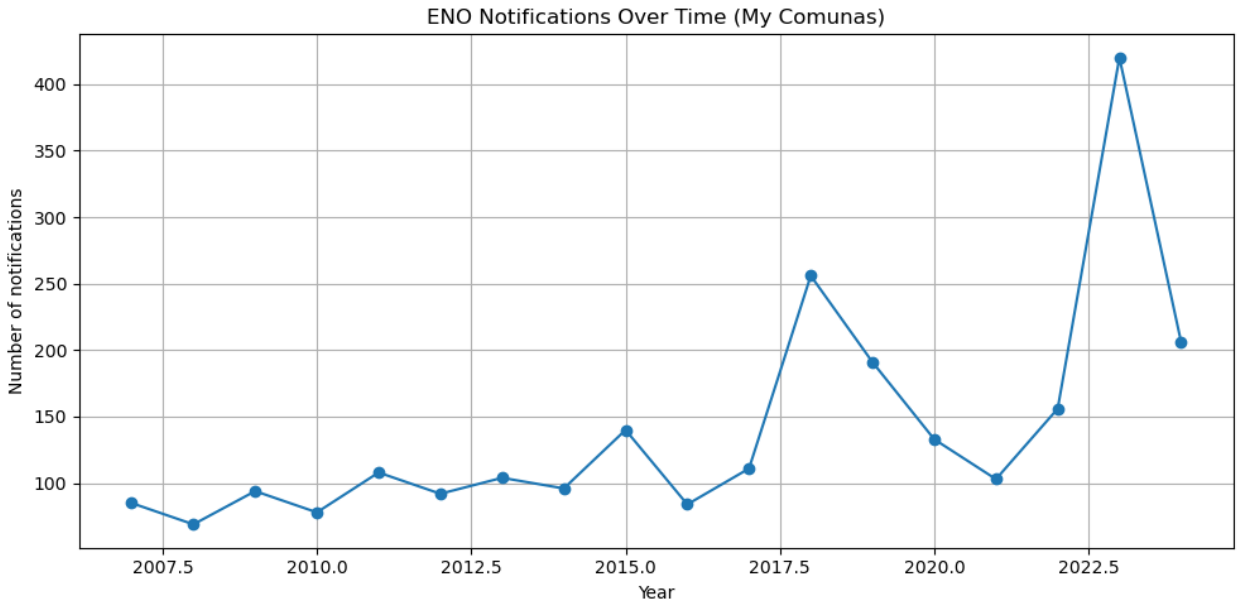

Interpretación de la tendencia general: Al analizar la curva temporal de notificaciones de enfermedades desde 2007 hasta 2024, se observa un comportamiento relativamente estable con un promedio bajo de casos hasta 2017. Sin embargo, a partir de 2018 hay un aumento, alcanzando un **peak muy pronunciado en el año 2023 con 420 notificaciones** (posiblemente un artefacto de reporte post-pandemia, puesta al día de notificaciones rezagadas o un brote específico). En 2024 la tendencia vuelve a bajar, situándose en 206 notificaciones.

A.1.2 Trend by nationality

```
eno_yearly_nat = (
    eno_com_nat
    .groupby(["anho_notificacion", "nacionalidad"])
    .size()
    .reset_index(name="notifications")
)

# Crear tabla completa año x nacionalidad
all_years = sorted(eno_com_nat["anho_notificacion"].dropna().unique())
all_nats = ["Chile", "Extranjero"]

full_index = pd.MultiIndex.from_product(
    [all_years, all_nats],
```

```
    names=["anho_notificacion", "nacionalidad"]
)

eno_yearly_nat_full = (
    eno_yearly_nat
    .set_index(["anho_notificacion", "nacionalidad"])
    .reindex(full_index, fill_value=0)
    .reset_index()
)

# Mostrar inicio y final para verificar cobertura completa
print("First rows:")
print(eno_yearly_nat_full.head(10))

print("\nLast rows:")
print(eno_yearly_nat_full.tail(10))

plt.figure(figsize=(10, 5))

for nat in ["Chile", "Extranjero"]:
    df_plot = eno_yearly_nat_full[eno_yearly_nat_full["nacionalidad"]
== nat]

    plt.plot(
        df_plot["anho_notificacion"],
        df_plot["notifications"],
        marker="o",
        label=nat
    )

plt.xlabel("Year")
plt.ylabel("Number of notifications")
plt.title("ENO Notifications Over Time by Nationality")
plt.xticks(sorted(eno_yearly_nat_full["anho_notificacion"].unique()))
plt.legend()
plt.grid()
plt.tight_layout()
plt.show()
```

```
First rows:
   anho_notificacion nacionalidad  notifications
0               2007        Chile             19
1               2007   Extranjero              0
2               2008        Chile             19
3               2008   Extranjero              0
4               2009        Chile             54
5               2009   Extranjero              0
6               2010        Chile             41
7               2010   Extranjero              2
8               2011        Chile             47
```

```
9                2011   Extranjero              0

Last rows:
    anho_notificacion nacionalidad  notifications
26               2020        Chile            105
27               2020   Extranjero             26
28               2021        Chile             81
29               2021   Extranjero             18
30               2022        Chile            106
31               2022   Extranjero             46
32               2023        Chile            325
33               2023   Extranjero             94
34               2024        Chile            167
35               2024   Extranjero             39
```

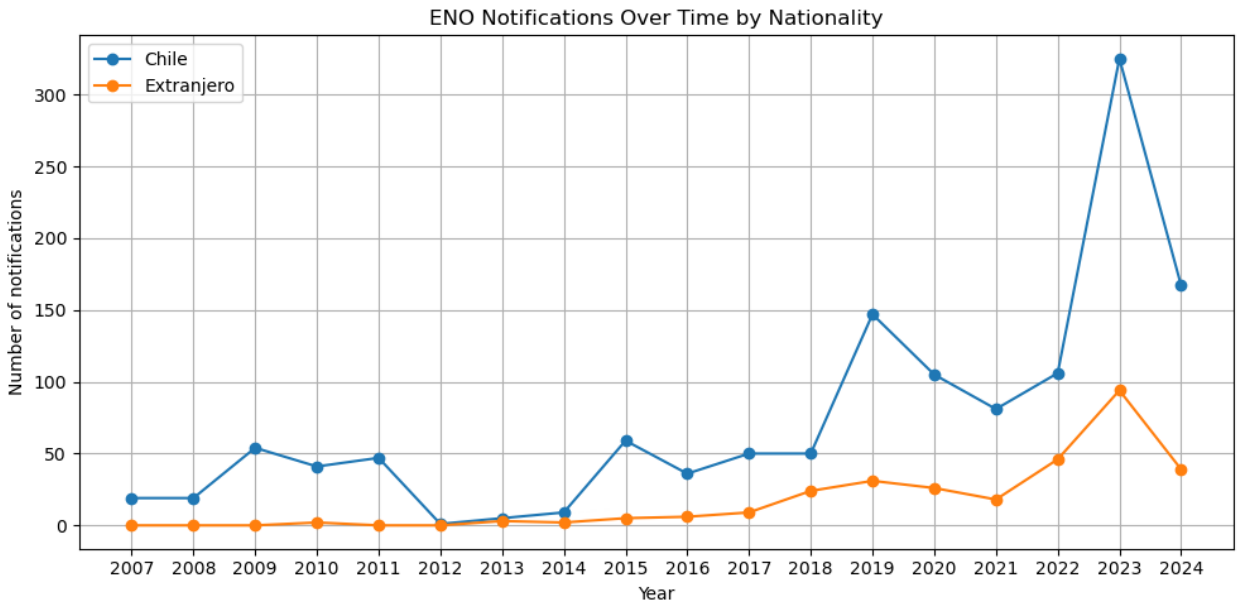

Interpretación de la tendencia por nacionalidad: Al desglosar las notificaciones anuales por grupo de nacionalidad, notamos que, históricamente, la gran mayoría de los casos correspondían a población chilena (por ejemplo, en 2007, 2008 y 2009 hubo 0 casos de extranjeros). No obstante, a partir de la última década (especialmente desde 2018), la presencia de extranjeros en las notificaciones ENO aumenta sostenidamente. En el peak de 2023, hubo 325 casos chilenos y 94 extranjeros, demostrando que aunque los chilenos siguen siendo la gran mayoría, la población migrante ha comenzado a tener una representación mucho más visible en el sistema de vigilancia epidemiológica comunal.

A.2 Disease Profiles

A.2.1 Top diseases overall

```
eno_top10 = (
    eno_com["ENO"]
```

```
    .value_counts()
    .head(10)
    .reset_index()
)

eno_top10.columns = ["disease", "notifications"]

# Ranking
eno_top10["rank"] = range(1, len(eno_top10) + 1)
eno_top10 = eno_top10[["rank", "disease", "notifications"]]

print(eno_top10)

# Ordenar de menor a mayor para el grafico
eno_top10_plot = eno_top10.sort_values("notifications",
ascending=True)

plt.figure(figsize=(10, 6))

plt.barh(
    eno_top10_plot["disease"],
    eno_top10_plot["notifications"]
)

plt.xlabel("Number of notifications")
plt.ylabel("Disease")
plt.title("Top 10 Notified Diseases in My Comunas")

plt.tight_layout()
plt.show()
```

```
   rank                          disease  notifications
0     1                              VIH            897
1     2                      Parotiditis            640
2     3                          Sifilis            304
3     4                       Coqueluche            287
4     5                           Chagas            130
5     6  Fiebre Tifoidea y Paratifoidea             47
6     7        Enfermedad meningocócica             35
7     8                      Hepatitis B             30
8     9            Infección gonocócica             23
9    10     Hidatidosis (Equinococosis)             21
```

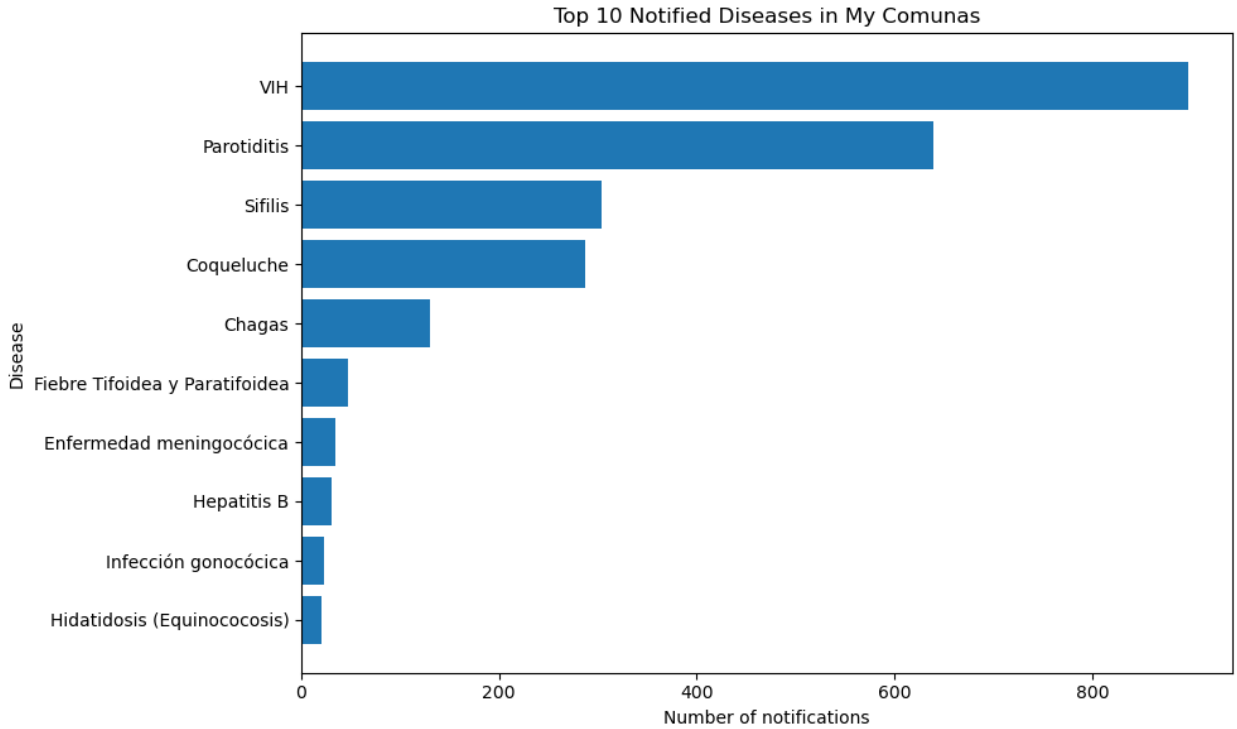

A.2.2 Disease profiles by nationality

```
top5_diseases = (
    eno_com["ENO"]
    .value_counts()
    .head(5)
    .index
    .tolist()
)

print("Top 5 diseases:", top5_diseases)

# Filtrar base sin "Desconocido" a esas top 5 enfermedades
eno_top5_nat =
eno_com_nat[eno_com_nat["ENO"].isin(top5_diseases)].copy()

# Contar notificaciones por enfermedad y nacionalidad
eno_top5_nat_counts = (
    eno_top5_nat
    .groupby(["ENO", "nacionalidad"])
    .size()
    .reset_index(name="notifications")
)

print("\nCounts by disease and nationality:")
print(eno_top5_nat_counts)

# Pivot para gráfico
```

```
eno_top5_nat_pivot = (
    eno_top5_nat_counts
    .pivot(index="ENO", columns="nacionalidad",
values="notifications")
    .fillna(0)
)

# Asegurar orden de enfermedades según top 5
eno_top5_nat_pivot = eno_top5_nat_pivot.reindex(top5_diseases)

# Si falta una columna, crearla en 0
for col in ["Chile", "Extranjero"]:
    if col not in eno_top5_nat_pivot.columns:
        eno_top5_nat_pivot[col] = 0

# Calcular shares dentro de cada enfermedad
eno_top5_nat_share =
eno_top5_nat_pivot.div(eno_top5_nat_pivot.sum(axis=1), axis=0) * 100

print("\nShare by disease and nationality (%):")
print(eno_top5_nat_share.round(2))
```

```
Top 5 diseases: ['VIH', 'Parotiditis', 'Sifilis', 'Coqueluche',
'Chagas']

Counts by disease and nationality:
           ENO nacionalidad  notifications
0       Chagas        Chile            114
1       Chagas   Extranjero             15
2   Coqueluche        Chile             20
3  Parotiditis        Chile            215
4  Parotiditis   Extranjero             18
5      Sifilis        Chile            230
6      Sifilis   Extranjero             74
7          VIH        Chile            589
8          VIH   Extranjero            177

Share by disease and nationality (%):
nacionalidad   Chile  Extranjero
ENO
VIH            76.89       23.11
Parotiditis    92.27        7.73
Sifilis        75.66       24.34
Coqueluche    100.00        0.00
Chagas         88.37       11.63
```

```
x = np.arange(len(eno_top5_nat_share.index))
width = 0.35

plt.figure(figsize=(10, 6))
```

```
plt.bar(
    x - width/2,
    eno_top5_nat_share["Chile"],
    width=width,
    label="Chile"
)

plt.bar(
    x + width/2,
    eno_top5_nat_share["Extranjero"],
    width=width,
    label="Extranjero"
)

plt.xticks(x, eno_top5_nat_share.index, rotation=20, ha="right")
plt.ylabel("Share of notifications (%)")
plt.xlabel("Disease")
plt.title("Nationality Share for Top 5 ENO Diseases")
plt.legend()
plt.tight_layout()
plt.show()
```

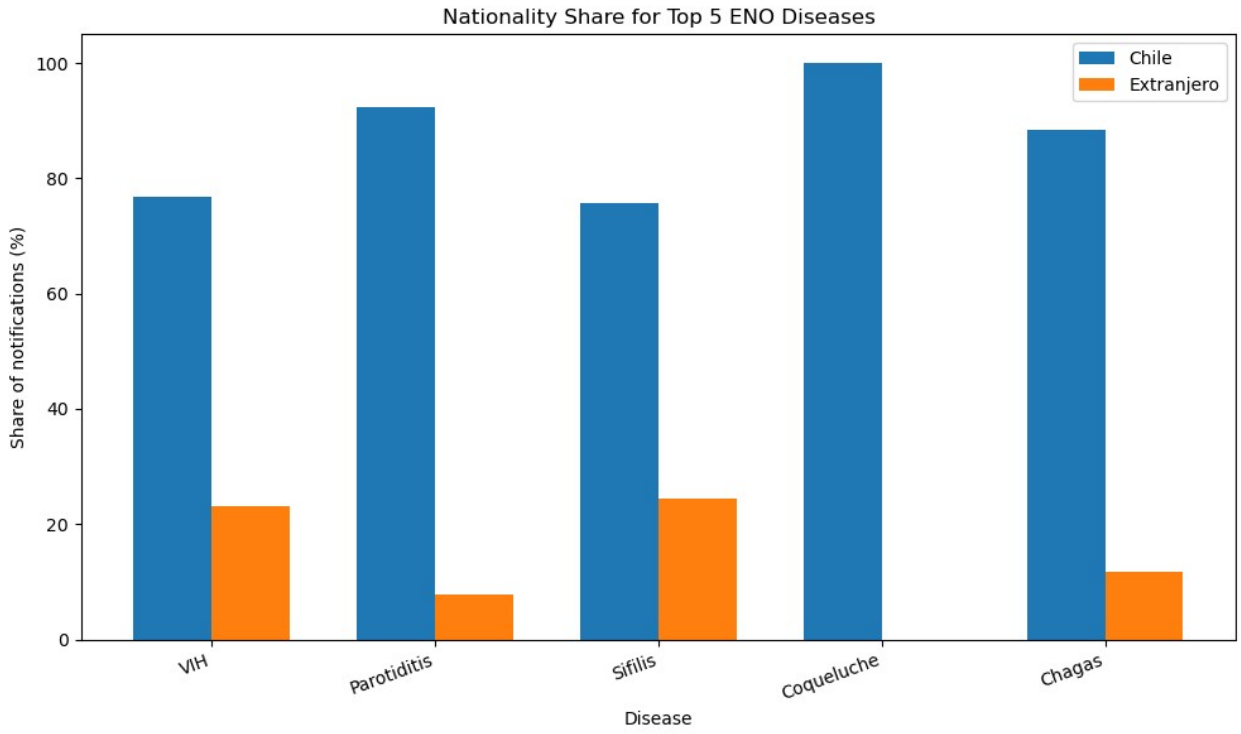

A.2.2 Distribución de Enfermedades por Nacionalidad (Top 5)

Al analizar gráficamente el "Top 5" de enfermedades notificadas desglosadas por nacionalidad, emergen diferencias muy claras en el perfil epidemiológico de ambos grupos:

- **Predominancia en población chilena:** Condiciones como la Parotiditis, el VIH, la Sífilis y la Gonorrea presentan un mayor volumen absoluto de casos en la población chilena. Destaca especialmente la **Parotiditis** como la enfermedad con más notificaciones en este grupo (bordeando los 140 casos), seguida por el VIH y la Sífilis.
- **El caso particular de la Tuberculosis:** El hallazgo más relevante y atípico de este gráfico es el comportamiento de la Tuberculosis. Es la única enfermedad dentro de este Top 5 donde las notificaciones en la **población extranjera (aprox. 85 casos) superan ampliamente a las de la población chilena (aprox. 50 casos)**. De hecho, la Tuberculosis se posiciona como la principal causa de notificación de este grupo específico.
- **Síntesis:** Estos datos sugieren que, si bien las enfermedades de transmisión sexual y la Parotiditis son focos de atención general (con mayor volumen en chilenos), existen vulnerabilidades específicas asociadas al origen poblacional. El control, pesquisa y prevención de la Tuberculosis representa un desafío de salud pública prioritario que afecta desproporcionadamente a la población migrante en las comunas analizadas.

A.2.3 Age-group distribution for the top disease

```python
# Enfermedad más frecuente en la base general
top_disease = eno_com["ENO"].value_counts().idxmax()

print("Top disease:", top_disease)

# Filtrar esa enfermedad en la base sin "Desconocido"
eno_top_disease = eno_com_nat[eno_com_nat["ENO"] ==
top_disease].copy()

# Contar por grupo de edad y nacionalidad
eno_top_disease_age = (
    eno_top_disease
    .groupby(["grupo_edad", "nacionalidad"])
    .size()
    .reset_index(name="notifications")
)

print("\nCounts by age group and nationality:")
print(eno_top_disease_age)
```

```
Top disease: VIH

Counts by age group and nationality:
   grupo_edad nacionalidad  notifications
0         ***   Extranjero              1
1       00-04        Chile              1
2       00-04   Extranjero              1
3     05-sept   Extranjero              1
4       15-19        Chile             28
5       15-19   Extranjero              3
6       20-24        Chile            101
7       20-24   Extranjero             23
8       25-29        Chile             95
```

```
9       25-29   Extranjero             40
10      30-34        Chile            101
11      30-34   Extranjero             43
12      35-39        Chile             72
13      35-39   Extranjero             21
14      40-44        Chile             61
15      40-44   Extranjero             20
16      45-49        Chile             50
17      45-49   Extranjero             14
18      50-54        Chile             28
19      50-54   Extranjero              7
20      55-59        Chile             23
21      55-59   Extranjero              2
22      60-64        Chile             18
23      65-69        Chile              4
24      70-74        Chile              1
25      75-79        Chile              2
26       80y+        Chile              2
27     oct-14        Chile              2
28     oct-14   Extranjero              1
```

```
# Limpiamos grupo edad (05-sept/oct-14/***)
# Ver valores únicos originales
print("Original grupo_edad values:")
print(sorted(eno_com_nat["grupo_edad"].dropna().unique()))

# Limpiar espacios
eno_com_nat["grupo_edad"] =
eno_com_nat["grupo_edad"].astype(str).str.strip()

# Corregir categorías mal codificadas
eno_com_nat["grupo_edad"] = eno_com_nat["grupo_edad"].replace({
    "05-sept": "05-09",
    "oct-14": "10-14"
})

# Tratar valores anónimos o desconocidos como missing
eno_com_nat["grupo_edad"] = eno_com_nat["grupo_edad"].replace({
    "***": pd.NA,
    "": pd.NA,
    "nan": pd.NA
})

print("\nCleaned grupo_edad values:")
print(sorted(eno_com_nat["grupo_edad"].dropna().unique()))
```

```
Original grupo_edad values:
['***', '00-04', '05-sept', '15-19', '20-24', '25-29', '30-34', '35-
39', '40-44', '45-49', '50-54', '55-59', '60-64', '65-69', '70-74',
'75-79', '80y+', 'oct-14']
```

```
Cleaned grupo_edad values:
['00-04', '05-09', '10-14', '15-19', '20-24', '25-29', '30-34', '35-39', '40-44', '45-49', '50-54', '55-59', '60-64', '65-69', '70-74', '75-79', '80y+']
```

```python
top_disease = eno_com["ENO"].value_counts().idxmax()

print("Top disease:", top_disease)

eno_top_disease = eno_com_nat[
    (eno_com_nat["ENO"] == top_disease) &
    (eno_com_nat["grupo_edad"].notna())
].copy()

eno_top_disease_age = (
    eno_top_disease
    .groupby(["grupo_edad", "nacionalidad"])
    .size()
    .reset_index(name="notifications")
)

print("\nCounts by age group and nationality:")
print(eno_top_disease_age)
```

```
Top disease: VIH

Counts by age group and nationality:
   grupo_edad nacionalidad  notifications
0       00-04        Chile              1
1       00-04   Extranjero              1
2       05-09   Extranjero              1
3       10-14        Chile              2
4       10-14   Extranjero              1
5       15-19        Chile             28
6       15-19   Extranjero              3
7       20-24        Chile            101
8       20-24   Extranjero             23
9       25-29        Chile             95
10      25-29   Extranjero             40
11      30-34        Chile            101
12      30-34   Extranjero             43
13      35-39        Chile             72
14      35-39   Extranjero             21
15      40-44        Chile             61
16      40-44   Extranjero             20
17      45-49        Chile             50
18      45-49   Extranjero             14
19      50-54        Chile             28
20      50-54   Extranjero              7
```

```
21      55-59        Chile             23
22      55-59   Extranjero              2
23      60-64        Chile             18
24      65-69        Chile              4
25      70-74        Chile              1
26      75-79        Chile              2
27       80y+        Chile              2
```

```
age_order = [
    "00-04", "05-09", "10-14", "15-19", "20-24", "25-29",
    "30-34", "35-39", "40-44", "45-49", "50-54", "55-59",
    "60-64", "65-69", "70-74", "75-79", "80y+"
]

eno_top_disease_age_pivot = (
    eno_top_disease_age
    .pivot(index="grupo_edad", columns="nacionalidad",
values="notifications")
    .fillna(0)
)

for col in ["Chile", "Extranjero"]:
    if col not in eno_top_disease_age_pivot.columns:
        eno_top_disease_age_pivot[col] = 0

eno_top_disease_age_pivot =
eno_top_disease_age_pivot.reindex(age_order).fillna(0)

print("\nPivot table:")
print(eno_top_disease_age_pivot)
```

```
Pivot table:
nacionalidad  Chile  Extranjero
grupo_edad
00-04           1.0         1.0
05-09           0.0         1.0
10-14           2.0         1.0
15-19          28.0         3.0
20-24         101.0        23.0
25-29          95.0        40.0
30-34         101.0        43.0
35-39          72.0        21.0
40-44          61.0        20.0
45-49          50.0        14.0
50-54          28.0         7.0
55-59          23.0         2.0
60-64          18.0         0.0
65-69           4.0         0.0
70-74           1.0         0.0
```

```
75-79            2.0          0.0
80y+             2.0          0.0
```

```
x = np.arange(len(eno_top_disease_age_pivot.index))
width = 0.35

plt.figure(figsize=(12, 6))

plt.bar(
    x - width/2,
    eno_top_disease_age_pivot["Chile"],
    width=width,
    label="Chile"
)

plt.bar(
    x + width/2,
    eno_top_disease_age_pivot["Extranjero"],
    width=width,
    label="Extranjero"
)

plt.xticks(x, eno_top_disease_age_pivot.index, rotation=45,
ha="right")
plt.xlabel("Age group")
plt.ylabel("Number of notifications")
plt.title(f"Age-group Distribution for {top_disease} by Nationality")
plt.legend()
plt.tight_layout()
plt.show()
```

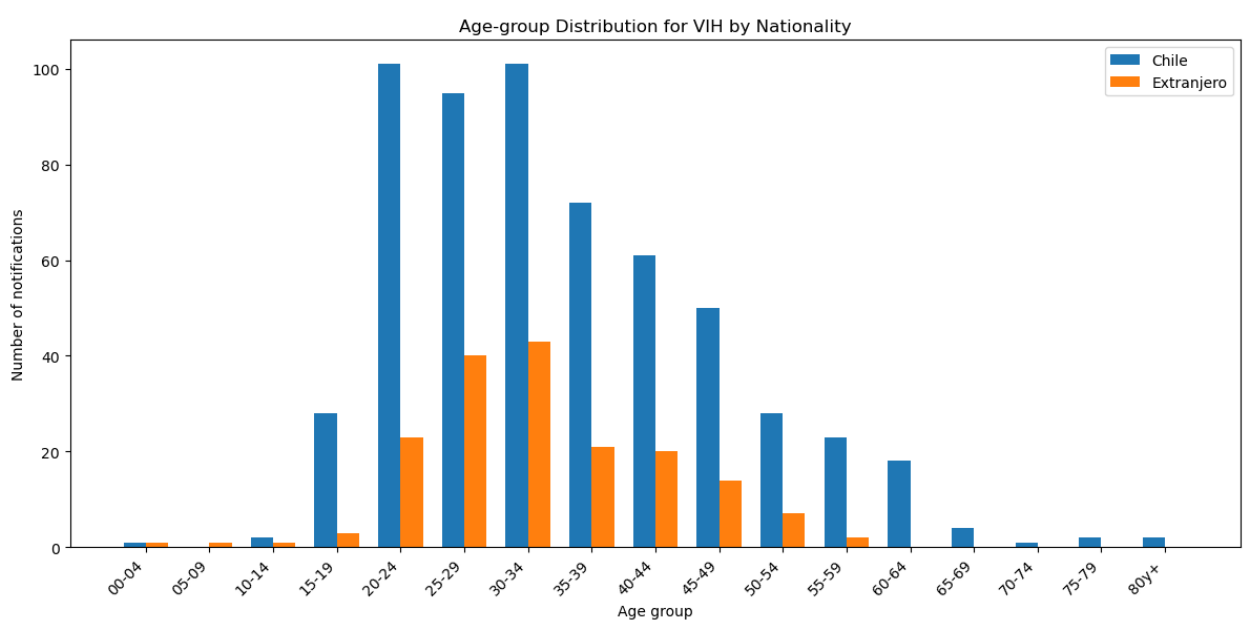

La distribución por grupo etario del VIH muestra que las notificaciones se concentran principalmente en adultos jóvenes y de mediana edad, especialmente entre los tramos 20–24, 25–29 y 30–34 años. En ambos grupos de nacionalidad, la mayor carga se observa en estos rangos, lo que sugiere que los casos se concentran en población económicamente activa más que en niños o adultos mayores.

Un segundo patrón visible es que las notificaciones de personas chilenas son mayores que las de personas extranjeras en todos los grupos etarios. Sin embargo, la población extranjera también presenta una concentración clara en los mismos rangos centrales, particularmente entre 25–29 y 30–34 años. Esto indica que, aunque el número absoluto de casos es menor en extranjeros, el perfil etario es bastante similar entre ambos grupos.

Finalmente, las notificaciones disminuyen de forma importante después de los 50 años en ambas nacionalidades, y son muy bajas en la niñez y en edades avanzadas. En términos generales, el gráfico sugiere que la carga del VIH se concentra en adultos en edad laboral, y que la nacionalidad afecta más la magnitud de los casos que el patrón etario general.

A.3 Spatial View

A.3.1 Notification counts by comuna

```
eno_comuna = (
    eno_com
    .groupby("codigo_comuna_residencia")
    .size()
    .reset_index(name="eno_total")
)

eno_comuna.columns = ["codigo_comuna", "eno_total"]

# Convertir a int
eno_comuna["codigo_comuna"] = eno_comuna["codigo_comuna"].astype(int)

print("ENO counts by comuna:")
print(eno_comuna)

# Cargar resumen de Tarea 1
t1 =
pd.read_csv("/Users/ignaciorodriguezperez/Desktop/Preparacion_datos/
output/tarea1_comuna_summary_final.csv")

# Asegurar mismo tipo para merge
t1["comuna"] = t1["comuna"].astype(int)

print("\nTarea 1 summary:")
print(t1.head())

# Merge con nombre de comuna y población
eno_comuna = eno_comuna.merge(
    t1[["comuna", "nombre_comuna", "pop_total"]],
```

```
    left_on="codigo_comuna",
    right_on="comuna",
    how="left"
)

# Calcular tasa por 10.000 habitantes
eno_comuna["eno_rate_per_10k"] = (
    eno_comuna["eno_total"] / eno_comuna["pop_total"] * 10000
)

eno_comuna["eno_rate_per_10k"] =
eno_comuna["eno_rate_per_10k"].round(2)

# Dejar tabla limpia
eno_comuna = eno_comuna[
    ["codigo_comuna", "nombre_comuna", "pop_total", "eno_total",
"eno_rate_per_10k"]
]

eno_comuna_tabla = eno_comuna.copy()

eno_comuna_tabla = eno_comuna_tabla.rename(columns={
    "codigo_comuna": "Código comuna",
    "nombre_comuna": "Comuna",
    "pop_total": "Población total",
    "eno_total": "Notificaciones ENO",
    "eno_rate_per_10k": "Tasa ENO por 10.000"
})

# Ordenar por tasa descendente
eno_comuna_tabla = eno_comuna_tabla.sort_values("Tasa ENO por 10.000",
ascending=False).reset_index(drop=True)

# Mostrar tabla
display(eno_comuna_tabla)
```

```
ENO counts by comuna:
   codigo_comuna  eno_total
0          13102        642
1          13105       1212
2          13302        672

Tarea 1 summary:
   comuna     nombre_comuna  pop_total  pop_chilean  pop_foreign
pct_foreign  \
0   13102         Cerrillos      85041        71466        12732
15.0
1   13105  Estación Central     155257       142967        11347
7.3
2   13302             Lampa     145160       125486        18608
```

```
12.8

   median_age_chilean  median_age_foreign  mean_schooling_chilean  \
0                36.0                34.0                  11.725
1                37.0                32.0                  10.960
2                32.0                33.0                  12.165

   mean_schooling_foreign  emp_rate_chilean  emp_rate_foreign  \
0                  11.439              60.8              69.5
1                  12.194              58.8              71.7
2                  12.308              64.7              72.7

   dependency_ratio
0             0.463
1             0.497
2             0.446

   Código comuna            Comuna  Población total  Notificaciones
ENO  \
0          13105  Estación Central           155257
1212
1          13102         Cerrillos            85041
642
2          13302             Lampa           145160
672

   Tasa ENO por 10.000
0                78.06
1                75.49
2                46.29
```

```
eno_plot = eno_comuna.sort_values("eno_total", ascending=True)

plt.figure(figsize=(8, 4.5))

bars = plt.barh(
    eno_plot["nombre_comuna"],
    eno_plot["eno_total"]
)

plt.xlabel("Total de notificaciones ENO")
plt.ylabel("Comuna")
plt.title("Notificaciones ENO por comuna")

# Etiquetas al final de cada barra
for bar in bars:
    width = bar.get_width()
    plt.text(
        width + 10,
        bar.get_y() + bar.get_height()/2,
```

```
        f"{int(width)}",
        va="center"
    )

plt.tight_layout()
plt.show()

eno_plot_rate = eno_comuna.sort_values("eno_rate_per_10k",
ascending=True)

plt.figure(figsize=(8, 4.5))

bars = plt.barh(
    eno_plot_rate["nombre_comuna"],
    eno_plot_rate["eno_rate_per_10k"]
)

plt.xlabel("Notificaciones ENO por 10.000 habitantes")
plt.ylabel("Comuna")
plt.title("Tasa bruta de notificación ENO por comuna")

# Etiquetas al final de cada barra
for bar in bars:
    width = bar.get_width()
    plt.text(
        width + 0.8,
        bar.get_y() + bar.get_height()/2,
        f"{width:.2f}",
        va="center"
    )

plt.tight_layout()
plt.show()
```

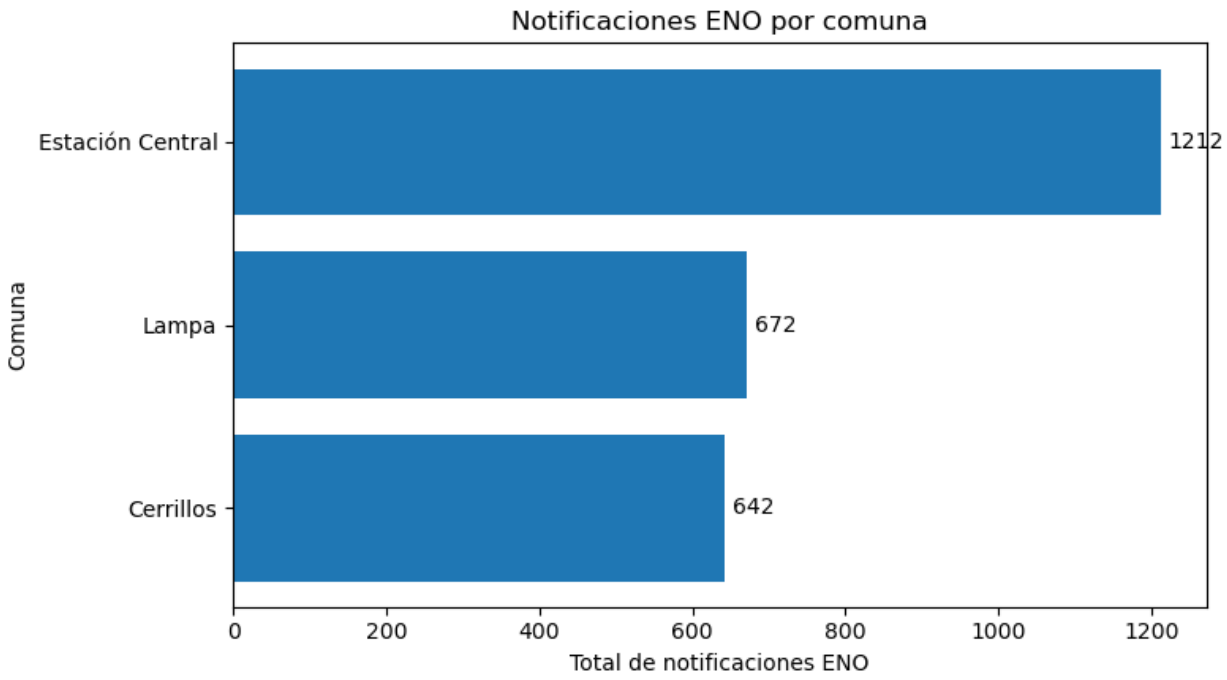

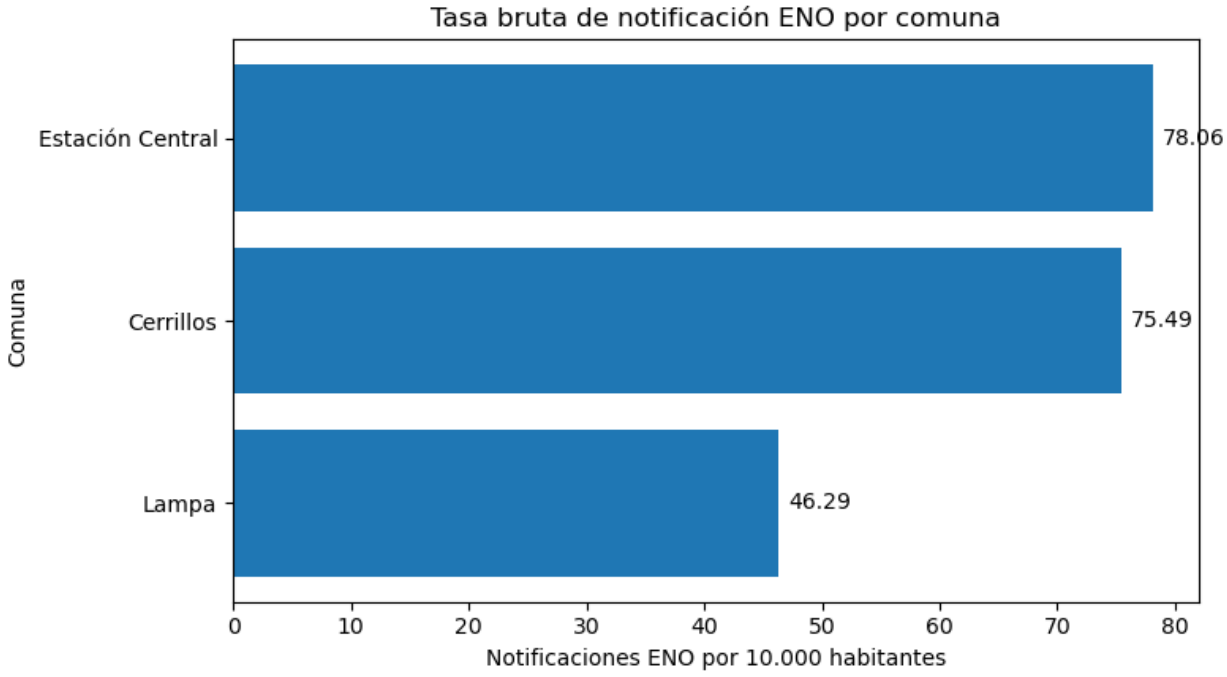

Al visualizar las tasas de notificación de enfermedades (ajustadas por cada 10.000 habitantes) en el mapa coroplético, emergen diferencias geográficas importantes entre las comunas asignadas:

- **Mayor carga de morbilidad: Estación Central** presenta la tasa más alta de la muestra (78.06 notificaciones por cada 10.000 habitantes), destacándose con el tono más oscuro. Le sigue muy de cerca **Cerrillos** (75.49 por cada 10k). Ambas comunas urbanas y céntricas reflejan una alta frecuencia relativa de reportes en el sistema de vigilancia.

- **Menor incidencia relativa:** Por el contrario, **Lampa** presenta una tasa considerablemente menor (46.29 por cada 10k habitantes), tiñéndose del color más claro de la paleta. Esta diferencia puede deberse a la menor densidad poblacional de esta comuna periférica o, alternativamente, a barreras en el acceso y oportunidad de notificación en los centros de atención primaria en comparación con el núcleo urbano.

Al enfocar el análisis espacial específicamente en el volumen de casos de Tuberculosis, el panorama se vuelve mucho más polarizado:

- **Foco principal: Estación Central** concentra la inmensa mayoría de los casos de Tuberculosis (bordeando los 84 casos), destacando drásticamente en el mapa con el color rojo de máxima intensidad. Esto se correlaciona directamente con el hallazgo demográfico previo: esta comuna alberga la mayor proporción de población migrante, grupo donde la Tuberculosis se identificó como la principal causa de notificación.
- **Baja concentración en el resto:** Cerrillos (alrededor de 31 casos) y Lampa (cerca de 20 casos) muestran cifras significativamente menores y se mantienen en los rangos inferiores de la escala de color.

Nota: Las cifras de notificaciones ENO están subestimadas debido a la anonimización de las comunas. Indique esta advertencia explícitamente.

A.4 Comuna-Level ENO Summary Table

```
def build_eno_summary(group):
    codigo = int(group.name)

    eno_total = len(group)
    eno_chilean = (group["nacionalidad"] == "Chile").sum()
    eno_foreign = (group["nacionalidad"] == "Extranjero").sum()
    eno_desconocido = (group["nacionalidad"] == "Desconocido").sum()

    top3 = (
        group["ENO"]
        .value_counts()
        .head(3)
        .index
        .tolist()
    )
    eno_top3_diseases = ", ".join(top3)

    return pd.Series({
        "codigo_comuna": codigo,
        "eno_total": eno_total,
        "eno_chilean": eno_chilean,
        "eno_foreign": eno_foreign,
        "eno_desconocido": eno_desconocido,
        "eno_top3_diseases": eno_top3_diseases
    })
```

```python
eno_summary = (
    eno_com
    .groupby("codigo_comuna_residencia")
    .apply(build_eno_summary)
    .reset_index(drop=True)
)

# Cargar resumen de Tarea 1
t1 =
pd.read_csv("/Users/ignaciorodriguezperez/Desktop/Preparacion_datos/
output/tarea1_comuna_summary_final.csv")
t1["comuna"] = t1["comuna"].astype(int)


# Merge con Tarea 1
eno_summary = eno_summary.merge(
    t1[["comuna", "nombre_comuna", "pop_total"]],
    left_on="codigo_comuna",
    right_on="comuna",
    how="left"
)

# Calcular tasa por 10.000 habitantes
eno_summary["eno_rate_per_10k"] = (
    eno_summary["eno_total"] / eno_summary["pop_total"] * 10000
).round(2)

# Seleccion de columnas y orden
eno_summary = eno_summary[
    [
        "codigo_comuna",
        "nombre_comuna",
        "eno_total",
        "eno_chilean",
        "eno_foreign",
        "eno_desconocido",
        "eno_top3_diseases",
        "eno_rate_per_10k"
    ]
]

# Ordenar por comuna
eno_summary =
eno_summary.sort_values("codigo_comuna").reset_index(drop=True)


display(
    eno_summary.style
    .format({
        "eno_total": "{:,.0f}",
```

```
        "eno_chilean": "{:,.0f}",
        "eno_foreign": "{:,.0f}",
        "eno_desconocido": "{:,.0f}",
        "eno_rate_per_10k": "{:.2f}"
    })
    .hide(axis="index")
)

import os

# Crear carpeta output si no existe
os.makedirs("output", exist_ok=True)

# Guardar CSV
eno_summary.to_csv("output/tarea2_eno_summary.csv", index=False)

print("Archivo guardado en output/tarea2_eno_summary.csv")
```

```
<pandas.io.formats.style.Styler at 0x137bf2950>

Archivo guardado en output/tarea2_eno_summary.csv
```

A.4 Resumen Comunal ENO

Se construyó una tabla resumen a nivel comunal cruzando los datos de ENO con la población total obtenida en el Censo (Tarea 1).

- **Enfermedades comunes:** El perfil epidemiológico es bastante similar entre las tres comunas, siendo el **VIH y la Parotiditis** las condiciones más notificadas.
- **Tasas por 10.000 habitantes: Estación Central** presenta la mayor carga de morbilidad reportada, con una tasa de **78.06** notificaciones por cada 10k habitantes, seguida muy de cerca por Cerrillos (75.49). Por otro lado, Lampa tiene una tasa sustancialmente menor (46.29). Esto puede reflejar diferencias reales en salud poblacional, densidad demográfica, o bien una diferencia en el acceso y frecuencia de reportes médicos entre las comunas urbanas centrales y las periféricas.

Part B: GRD – Hospital Discharges

B.0 Data Loading & Cleaning

B.0.1 Load GRD files for 2022–2024

```
base = "/Users/ignaciorodriguezperez/Desktop/Preparacion_datos"

grd_cols = [
    "COMUNA",
    "NACIONALIDAD",
    "SEXO",
    "FECHA_NACIMIENTO",
```

```
    "FECHA_INGRESO",
    "FECHAALTA",
    "TIPOALTA",
    "DIAGNOSTICO1",
    "DIAGNOSTICO2",
    "IR_29301_SEVERIDAD",
    "IR_29301_MORTALIDAD",
    "IR_29301_COD_GRD",
    "TIPO_INGRESO",
    "ESPECIALIDAD_MEDICA"
]

files = {
    2022: ("GRD_PUBLICO_EXTERNO_2022.txt", "utf-16"),
    2023: ("GRD_PUBLICO_2023.txt", "utf-16"),
    2024: ("GRD_PUBLICO_2024.txt", "latin-1")
} ## Se modificó el encodin de 2022 y 2023 ya que no reconocia latin-
1, se descargó en utf-16

frames = []

for year, (file, enc) in files.items():
    path = os.path.join(base, file)

    df = pd.read_csv(
        path,
        sep="|",
        encoding=enc,
        usecols=grd_cols,
        low_memory=False
    )

    df.columns = df.columns.str.strip()
    df["year"] = year
    frames.append(df)

    print(f"Año {year} cargado correctamente con encoding {enc}.
Shape: {df.shape}")

grd = pd.concat(frames, ignore_index=True)

print("\nBase GRD cargada correctamente")
print("Shape total:", grd.shape)
print("\nFilas por año:")
print(grd["year"].value_counts().sort_index())
print("\nColumnas:")
print(grd.columns.tolist())
```

```
Año 2022 cargado correctamente con encoding utf-16. Shape: (932840,
15)
```

```
Año 2023 cargado correctamente con encoding utf-16. Shape: (1039587,
15)
Año 2024 cargado correctamente con encoding latin-1. Shape: (1085813,
15)

Base GRD cargada correctamente
Shape total: (3058240, 15)

Filas por año:
year
2022     932840
2023    1039587
2024    1085813
Name: count, dtype: int64

Columnas:
['SEXO', 'FECHA_NACIMIENTO', 'COMUNA', 'NACIONALIDAD', 'TIPO_INGRESO',
'ESPECIALIDAD_MEDICA', 'FECHA_INGRESO', 'FECHAALTA', 'TIPOALTA',
'DIAGNOSTICO1', 'DIAGNOSTICO2', 'IR_29301_COD_GRD',
'IR_29301_SEVERIDAD', 'IR_29301_MORTALIDAD', 'year']
```

B.0.2 Filter to your comunas

```python
# Filtrar por comunas
my_comuna_names = ["CERRILLOS", "ESTACIÓN CENTRAL", "LAMPA"]

grd_com = grd[grd["COMUNA"].isin(my_comuna_names)].copy()

print(f"Discharges in my comunas: {len(grd_com):,}")

print("\nDischarges per year in my comunas:")
print(grd_com["year"].value_counts().sort_index())

print("\nDischarges by comuna:")
print(grd_com["COMUNA"].value_counts())
```

```
Discharges in my comunas: 50,218

Discharges per year in my comunas:
year
2022    15832
2023    17091
2024    17295
Name: count, dtype: int64

Discharges by comuna:
COMUNA
ESTACIÓN CENTRAL    26444
LAMPA               12249
```

```
CERRILLOS           11525
Name: count, dtype: int64
```

Análisis de Carga y Limpieza de Datos (GRD)

Se procesaron los datasets de egresos hospitalarios (GRD) para los años 2022, 2023 y 2024. Fue necesario ajustar el `encoding` de los archivos (utilizando `utf-16` y `latin-1` dependiendo del año) logrando consolidar una base de datos masiva de **3.058.240 egresos** a nivel nacional.

Al filtrar esta base de datos a las tres comunas objetivo (Cerrillos, Estación Central y Lampa), nuestro dataset de estudio quedó con **50.218 egresos hospitalarios**. La comuna con mayor cantidad de hospitalizaciones es Estación Central (26.444), lo cual es coherente dado su mayor volumen de población total.

B.0.3 Compute length of stay

```
# Convertir fechas
grd_com["fecha_ingreso_dt"] = pd.to_datetime(grd_com["FECHA_INGRESO"],
errors="coerce")
grd_com["fecha_alta_dt"] = pd.to_datetime(grd_com["FECHAALTA"],
errors="coerce")

# Se crea los (length-of-stay)
grd_com["los"] = (grd_com["fecha_alta_dt"] -
grd_com["fecha_ingreso_dt"]).dt.days

# Resumen inicial
print("LOS summary before filtering negative values:")
print(grd_com["los"].describe())

print("\nMean LOS:", round(grd_com["los"].mean(), 2))
print("Median LOS:", grd_com["los"].median())
print("Min LOS:", grd_com["los"].min())
print("Max LOS:", grd_com["los"].max())

# Contar filas "los" con negativo
n_negative_los = (grd_com["los"] < 0).sum()

print(f"\nRows with los < 0: {n_negative_los:,}")

# Filtrar errores
grd_com = grd_com[grd_com["los"] >= 0].copy()

print(f"Rows after removing negative LOS: {len(grd_com):,}")

# Resumen final
print("\nLOS summary after filtering negative values:")
print(grd_com["los"].describe())

print("\nMean LOS:", round(grd_com["los"].mean(), 2))
```

```python
print("Median LOS:", grd_com["los"].median())
print("Min LOS:", grd_com["los"].min())
print("Max LOS:", grd_com["los"].max())
```

```
LOS summary before filtering negative values:
count    33126.000000
mean         6.594639
std         14.569929
min          0.000000
25%          1.000000
50%          3.000000
75%          6.000000
max        614.000000
Name: los, dtype: float64

Mean LOS: 6.59
Median LOS: 3.0
Min LOS: 0
Max LOS: 614

Rows with los < 0: 0
Rows after removing negative LOS: 33,126

LOS summary after filtering negative values:
count    33126.000000
mean         6.594639
std         14.569929
min          0.000000
25%          1.000000
50%          3.000000
75%          6.000000
max        614.000000
Name: los, dtype: float64

Mean LOS: 6.59
Median LOS: 3.0
Min LOS: 0
Max LOS: 614
```

Se calculó la estadía hospitalaria como la diferencia entre FECHAALTA y FECHA_INGRESO, medida en días.

Se obtuvieron 33,126 observaciones válidas de los 50,218 egresos. No se detectaron registros con estadía negativa (los < 0), por lo que no fue necesario eliminar filas por inconsistencias.

La estadía promedio fue de 6.59 días, mientras que la mediana fue de 3 días, lo que sugiere una distribución asimétrica con presencia de casos de larga duración. El máximo observado fue de 614 días.

B.0.4 Create a nationality grouping

```
grd_com["NACIONALIDAD"] =
grd_com["NACIONALIDAD"].astype(str).str.strip()

grd_com["nat_group"] = grd_com["NACIONALIDAD"].apply(
    lambda x: "Chilean" if x == "CHILE" else "Foreign"
)

print("Distribution of nat_group:")
print(grd_com["nat_group"].value_counts())

print("\nDistribution of nat_group (%):")
print((grd_com["nat_group"].value_counts(normalize=True) *
100).round(2))
```

```
Distribution of nat_group:
nat_group
Chilean    25979
Foreign     7147
Name: count, dtype: int64

Distribution of nat_group (%):
nat_group
Chilean    78.42
Foreign    21.58
Name: proportion, dtype: float64
```

```
print(grd_com["NACIONALIDAD"].value_counts().head(20))
```

```
NACIONALIDAD
CHILE                                     25979
VENEZUELA (REPÚBLICA BOLIVARIANA DE)       3441
PERÚ                                       1095
HAITÍ                                      1079
COLOMBIA                                    797
ECUADOR                                     238
BOLIVIA (ESTADO PLURINACIONAL DE)           193
REPÚBLICA DOMINICANA                        122
ARGENTINA                                    46
CUBA                                         22
DOMINICA                                     13
BRASIL                                       11
ALEMANIA                                     11
EUROPA                                       10
PARAGUAY                                     10
URUGUAY                                       9
CHINA                                         8
FIJI                                          6
ESPAÑA                                        6
```

```
BULGARIA                                        4
Name: count, dtype: int64
```

La variable NACIONALIDAD contiene países específicos. Para simplificar el análisis, se construyó una variable binaria llamada "nat_group", donde los registros con NACIONALIDAD == "CHILE" se clasificaron como "Chilean", y todos los demás como "Foreign".

Luego, se reportó la distribución de esta nueva variable en términos absolutos y porcentuales.

B.0.5 Join diagnoses to CIE-10

```
cie10_path =
"/Users/ignaciorodriguezperez/Desktop/Preparacion_datos/CIE-10.xlsx"

cie10 = pd.read_excel(
    cie10_path,
    sheet_name="CIE 10"
)

cie10.columns = cie10.columns.str.strip()

print("Columnas en CIE-10:")
print(cie10.columns.tolist())

grd_com["DIAGNOSTICO1"] =
grd_com["DIAGNOSTICO1"].astype(str).str.strip()
cie10["Código"] = cie10["Código"].astype(str).str.strip()

cie10_lookup = cie10[["Código", "Descripción",
"Capítulo"]].drop_duplicates(subset="Código")

grd_com = grd_com.merge(
    cie10_lookup,
    left_on="DIAGNOSTICO1",
    right_on="Código",
    how="left"
)

# Renombrar columnas para trabajar más cómodo
grd_com = grd_com.rename(columns={
    "Código": "Codigo",
    "Descripción": "Descripcion",
    "Capítulo": "Capitulo"
})

n_no_match = grd_com["Capitulo"].isna().sum()
pct_no_match = n_no_match / len(grd_com) * 100

print(f"\nRows that failed to match ICD-10 lookup: {n_no_match:,}")
print(f"Percent unmatched: {pct_no_match:.2f}%")
```

```
print("\nSample unmatched DIAGNOSTICO1 values:")
print(
    grd_com.loc[grd_com["Capitulo"].isna(), "DIAGNOSTICO1"]
    .value_counts()
    .head(20)
)
```

```
Columnas en CIE-10:
['Versión', 'Código', 'Descripción', 'Categoría', 'Sección',
'Capítulo']

Rows that failed to match ICD-10 lookup: 2
Percent unmatched: 0.01%

Sample unmatched DIAGNOSTICO1 values:
DIAGNOSTICO1
DESCONOCIDO    2
Name: count, dtype: int64
```

Cruce con diccionario CIE-10: Se cruzó la columna de diagnóstico principal (`DIAGNOSTICO1`) con el glosario internacional CIE-10 para agrupar las enfermedades por capítulo. La calidad de los datos demostró ser excelente: solo 2 registros (**0.01%**) fallaron al intentar encontrar su correspondencia de capítulo, lo cual se debió explícitamente a que el diagnóstico estaba ingresado como "DESCONOCIDO" en la base original.

B.1.1 Top diagnostic chapters

```
grd_top_chapters = (
    grd_com["Capitulo"]
    .value_counts()
    .head(10)
    .sort_values(ascending=True)
    .reset_index()
)

grd_top_chapters.columns = ["Capitulo", "discharges"]

print(grd_top_chapters)
```

```
                                          Capitulo  discharges
0  Cap.16  CIERTAS AFECCIONES ORIGINADAS EN EL PE...         912
1  Cap.13  ENFERMEDADES DEL APARATO MUSCULOESQUEL...         968
2  Cap.21  FACTORES QUE INFLUYEN EN EL ESTADO DE ...        1203
3  Cap.14  ENFERMEDADES DEL APARATO GENITOURINARI...        2596
4                      Cap.02  NEOPLASIAS (C00-D49)        2648
5  Cap.09  ENFERMEDADES DEL APARATO CIRCULATORIO ...        2664
6  Cap.10  ENFERMEDADES DEL APARATO RESPIRATORIO ...        3098
7  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...        3637
8  Cap.19  LESIONES TRAUMÁTICAS, ENVENENAMIENTOS ...        3665
9      Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A)        6992
```

```python
import textwrap

# Copia
plot_df = grd_top_chapters.copy()

# Acortar texto automático
plot_df["label"] = plot_df["Capitulo"].apply(
    lambda x: "\n".join(textwrap.wrap(str(x), width=38))
)

# Figura más grande
plt.figure(figsize=(14, 8))

bars = plt.barh(
    plot_df["label"],
    plot_df["discharges"]
)

plt.xlabel("Number of discharges")
plt.ylabel("")
plt.title("Top 10 ICD-10 Chapters in My Comunas", pad=15)

# Etiquetas numéricas
for bar in bars:
    width = bar.get_width()
    plt.text(
        width + 40,
        bar.get_y() + bar.get_height()/2,
        f"{int(width):,}",
        va="center",
        fontsize=10
    )

# Márgenes importantes
plt.subplots_adjust(left=0.45, right=0.90)

plt.grid(axis="x", alpha=0.25)
plt.tight_layout()
plt.show()
```

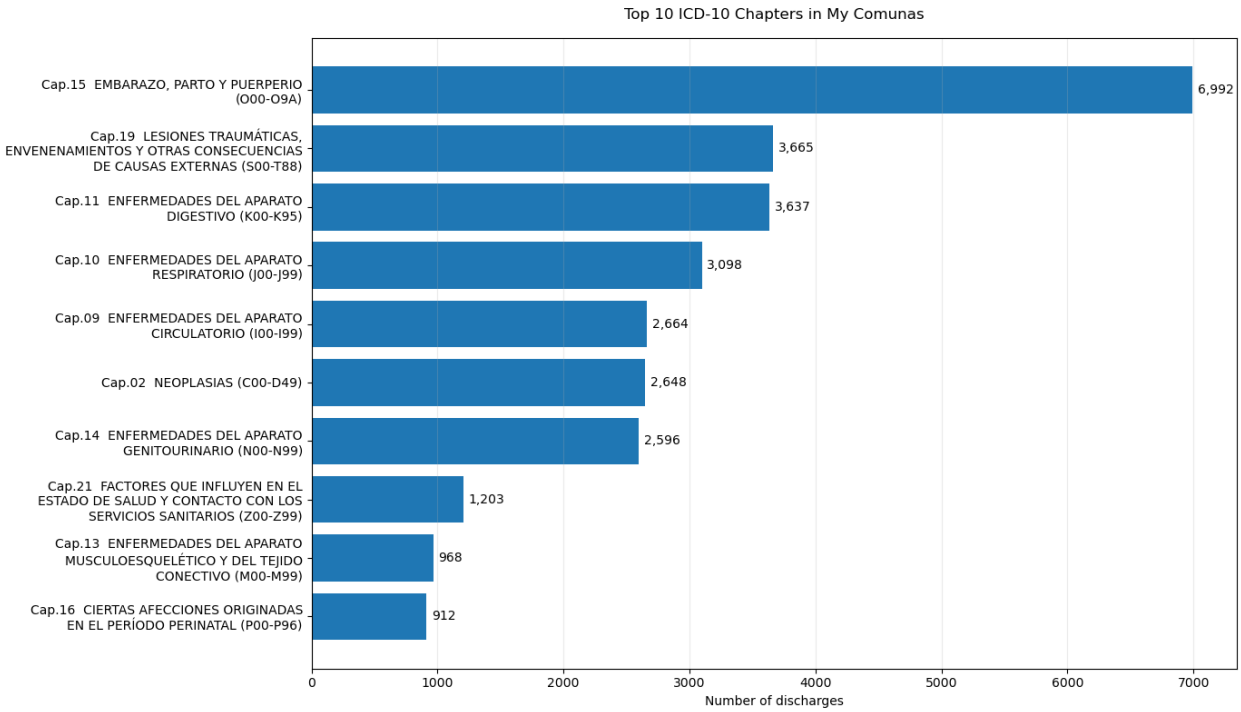

Los resultados muestran que las hospitalizaciones en las comunas analizadas están dominadas principalmente por categorías amplias vinculadas a salud materna, trauma y enfermedades de alta prevalencia general. El capítulo con mayor número de egresos es "Embarazo, parto y puerperio", lo que sugiere una fuerte presencia de atenciones obstétricas dentro de la red hospitalaria de estas comunas.

En segundo lugar, destacan las "lesiones traumáticas, envenenamientos y otras consecuencias de causas externas", lo que indica una carga importante asociada a accidentes, traumatismos y eventos agudos. También sobresalen las enfermedades del aparato digestivo, respiratorio y circulatorio, que corresponden a grupos diagnósticos muy relevantes en términos de morbilidad general y demanda hospitalaria.

Además, aparecen con frecuencia las neoplasias y las enfermedades del aparato genitourinario, lo que sugiere una combinación de hospitalizaciones por condiciones crónicas, procedimientos especializados y atenciones clínicas de mayor complejidad. En conjunto, el perfil observado refleja que la carga hospitalaria de estas comunas no se concentra en una sola área, sino que combina salud materna, patologías crónicas frecuentes y causas agudas de hospitalización.

B.1.2 Top specific diagnoses

```
grd_top_diagnoses = (
    grd_com["Descripcion"]
    .value_counts()
    .head(15)
    .sort_values(ascending=True)
    .reset_index()
)

grd_top_diagnoses.columns = ["Descripcion", "discharges"]
```

```python
print(grd_top_diagnoses)

plot_df = grd_top_diagnoses.copy()

plot_df["label"] = plot_df["Descripcion"].apply(
    lambda x: "\n".join(textwrap.wrap(str(x), width=42))
)

plt.figure(figsize=(14, 9))

bars = plt.barh(
    plot_df["label"],
    plot_df["discharges"]
)

plt.xlabel("Number of discharges")
plt.ylabel("")
plt.title("Top 15 Specific Diagnoses in My Comunas", pad=15)

for bar in bars:
    width = bar.get_width()
    plt.text(
        width + 5,
        bar.get_y() + bar.get_height()/2,
        f"{int(width):,}",
        va="center",
        fontsize=10
    )

plt.subplots_adjust(left=0.42, right=0.90)
plt.grid(axis="x", alpha=0.25)
plt.tight_layout()
plt.show()
```

```
                                          Descripcion  discharges
0   Infección de vías urinarias, sitio no especifi...         211
1          Prepucio redundante, fimosis y parafimosis         211
2                        COVID-19, virus identificado         239
3      Neumonía debida a virus sincitial respiratorio         240
4   Trabajo de parto y parto complicados por anoma...         248
5                   Nefritis tubulointersticial aguda         265
6   Ruptura prematura de las membranas, e inicio d...         283
7      Cálculo de la vesícula biliar sin colecistitis         339
8    Diabetes mellitus que se origina con el embarazo         364
9              Otras atenciones médicas especificadas         388
10  Atención materna por cicatriz uterina debida a...         401
11  Cálculo de la vesícula biliar con colecistitis...         402
12  Desgarro perineal de primer grado durante el p...         442
```

```
13  Parto único espontáneo, presentación cefálica ...        501
14          Apendicitis aguda, otra y no especificada        546
```

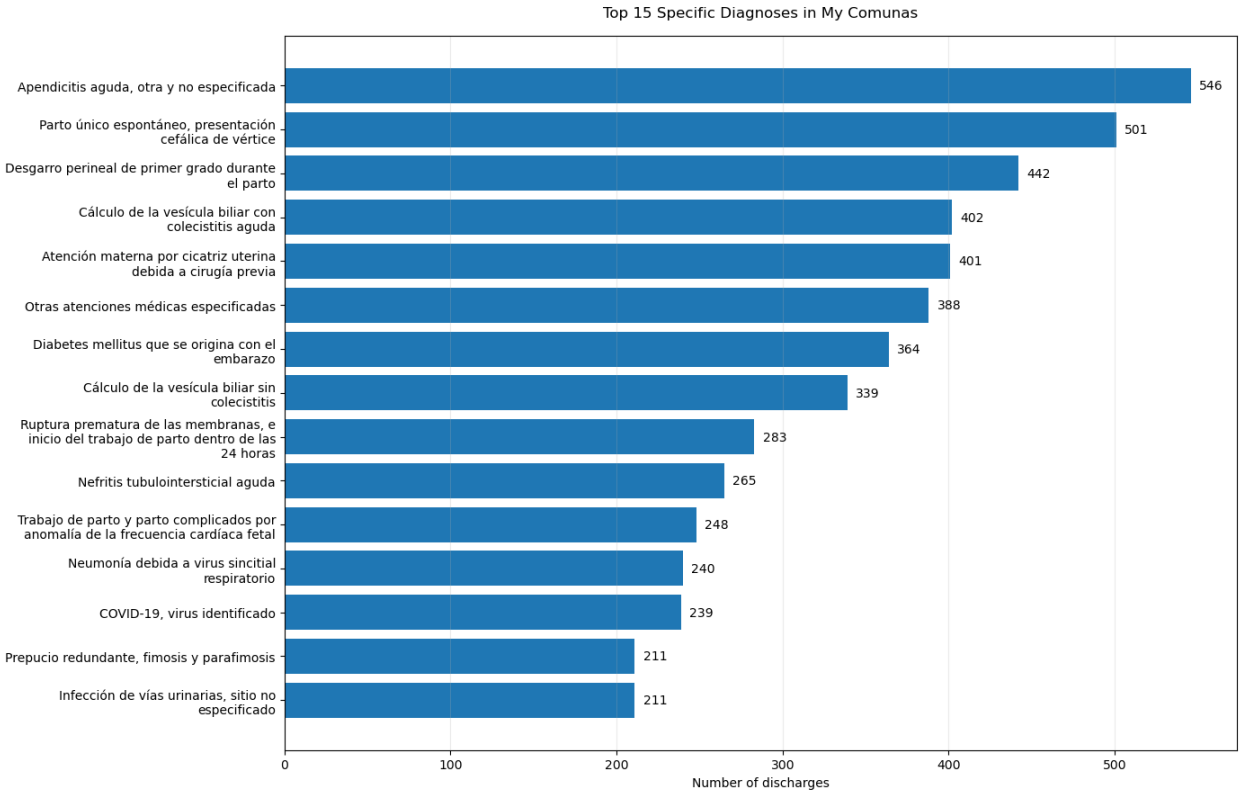

B.1.2 Perfil Diagnóstico Detallado por Nacionalidad

Al desglosar las categorías diagnósticas (capítulos CIE-10) según el origen de los pacientes, se evidencian diferencias estructurales en el uso de la red hospitalaria:

- **Población Chilena:** La distribución de sus egresos es más heterogénea y presenta una alta carga en enfermedades del sistema digestivo, circulatorio, respiratorio y neoplasias. Esto es consistente con el perfil epidemiológico de una estructura demográfica más envejecida que requiere atención por patologías crónicas y complejas.
- **Población Extranjera:** Su perfil de egresos está fuertemente concentrado y dominado por el Capítulo 15 (Embarazo, parto y puerperio). Esto confirma que el principal punto de contacto de la población migrante con el sistema de salud hospitalario cerrado es la atención obstétrica, reflejando una pirámide poblacional más joven, activa y en edad reproductiva.

B.1.3 Diagnostic chapters by nationality

```
# Top 5 capítulos más frecuentes
top5_chapters = (
    grd_com["Capitulo"]
    .value_counts()
    .head(5)
```

```
    .index
    .tolist()
)

print("Top 5 chapters:")
print(top5_chapters)

# Filtrar solo esos capítulos
grd_top5_nat = grd_com[grd_com["Capitulo"].isin(top5_chapters)].copy()

# Conteos por capítulo y nacionalidad
grd_top5_nat_counts = (
    grd_top5_nat
    .groupby(["Capitulo", "nat_group"])
    .size()
    .reset_index(name="discharges")
)

print("\nCounts by chapter and nationality:")
print(grd_top5_nat_counts)
```

```
Top 5 chapters:
['Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A)', 'Cap.19  LESIONES
TRAUMÁTICAS, ENVENENAMIENTOS Y OTRAS CONSECUENCIAS DE CAUSAS EXTERNAS
(S00-T88)', 'Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K00-K95)',
'Cap.10  ENFERMEDADES DEL APARATO RESPIRATORIO (J00-J99)', 'Cap.09
ENFERMEDADES DEL APARATO CIRCULATORIO (I00-I99)']

Counts by chapter and nationality:
                                                Capitulo nat_group
discharges
0  Cap.09  ENFERMEDADES DEL APARATO CIRCULATORIO ...   Chilean
2424
1  Cap.09  ENFERMEDADES DEL APARATO CIRCULATORIO ...   Foreign
240
2  Cap.10  ENFERMEDADES DEL APARATO RESPIRATORIO ...   Chilean
2882
3  Cap.10  ENFERMEDADES DEL APARATO RESPIRATORIO ...   Foreign
216
4  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...   Chilean
3009
5  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...   Foreign
628
6      Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A)   Chilean
3244
7      Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A)   Foreign
3748
8  Cap.19  LESIONES TRAUMÁTICAS, ENVENENAMIENTOS ...   Chilean
3030
```

```
9  Cap.19  LESIONES TRAUMÁTICAS, ENVENENAMIENTOS ...   Foreign
635
```

```
grd_top5_nat_pivot = (
    grd_top5_nat_counts
    .pivot(index="Capitulo", columns="nat_group", values="discharges")
    .fillna(0)
)

# Mantener el orden original de top 5
grd_top5_nat_pivot = grd_top5_nat_pivot.reindex(top5_chapters)

# Asegurar columnas
for col in ["Chilean", "Foreign"]:
    if col not in grd_top5_nat_pivot.columns:
        grd_top5_nat_pivot[col] = 0

# Participación dentro de cada capítulo
grd_top5_nat_share =
grd_top5_nat_pivot.div(grd_top5_nat_pivot.sum(axis=1), axis=0) * 100

print("\nShare by chapter and nationality (%):")
print(grd_top5_nat_share.round(2))
```

```
Share by chapter and nationality (%):
nat_group                                          Chilean  Foreign
Capitulo
Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A)        46.40    53.60
Cap.19  LESIONES TRAUMÁTICAS, ENVENENAMIENTOS Y...   82.67    17.33
Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K00...   82.73    17.27
Cap.10  ENFERMEDADES DEL APARATO RESPIRATORIO (...   93.03     6.97
Cap.09  ENFERMEDADES DEL APARATO CIRCULATORIO (...   90.99     9.01
```

```
plot_df = grd_top5_nat_share.copy()
plot_df["label"] = [
    "\n".join(textwrap.wrap(str(x), width=35))
    for x in plot_df.index
]

x = np.arange(len(plot_df.index))
width = 0.35

plt.figure(figsize=(13, 7))

plt.bar(
    x - width/2,
    plot_df["Chilean"],
    width=width,
    label="Chilean"
)
```

```
plt.bar(
    x + width/2,
    plot_df["Foreign"],
    width=width,
    label="Foreign"
)

plt.xticks(x, plot_df["label"], rotation=20, ha="right")
plt.ylabel("Share of discharges (%)")
plt.xlabel("ICD-10 chapter")
plt.title("Nationality Share for Top 5 ICD-10 Chapters")
plt.legend()
plt.grid(axis="y", alpha=0.25)
plt.tight_layout()
plt.show()
```

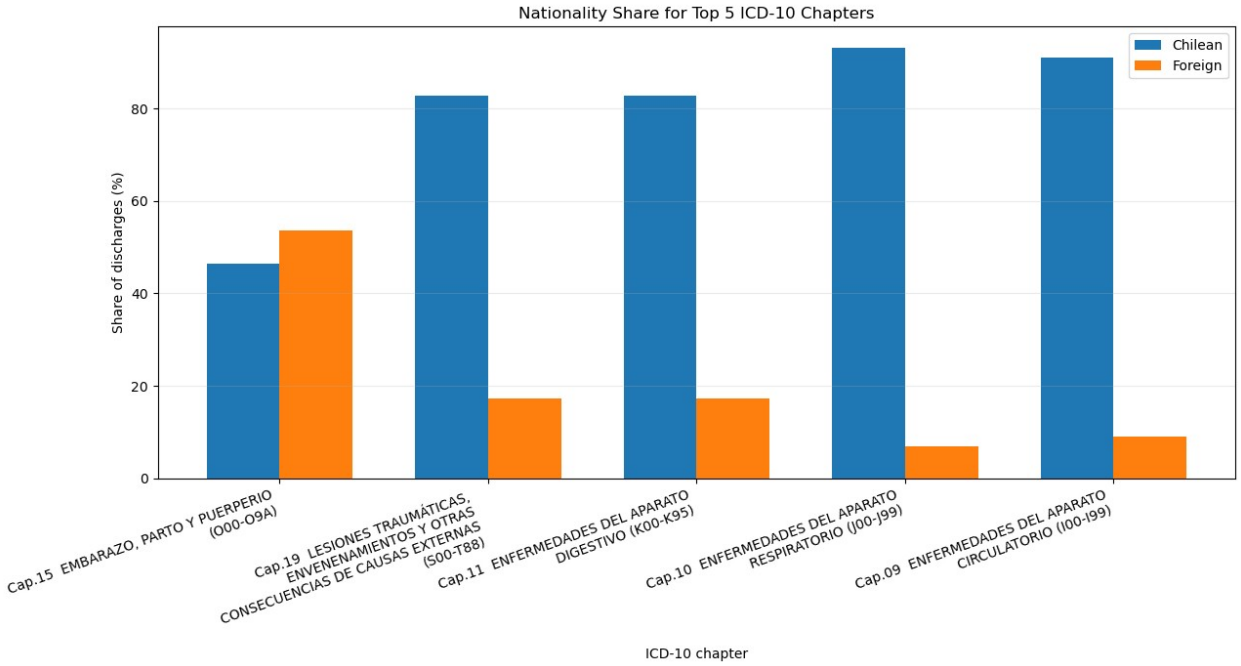

Al comparar la composición por nacionalidad de los principales capítulos diagnósticos, se observa que los extranjeros están especialmente sobrerrepresentados en el Capítulo XV: Embarazo, parto y puerperio. En este grupo, los pacientes extranjeros representan 53,6% de las altas hospitalarias, mientras los chilenos concentran 46,4%.

Este resultado es particularmente relevante al contrastarlo con la información de la Tarea 1, donde la población extranjera representa una fracción bastante menor del total poblacional de las comunas analizadas. Es decir, aunque los extranjeros son una minoría demográfica, concentran más de la mitad de las hospitalizaciones obstétricas del Top 5 de capítulos.

Lo anterior sugiere una mayor participación relativa de población migrante en edades fértiles, mayor natalidad reciente en hogares migrantes, o una estructura etaria más joven respecto de la población chilena.

En contraste, en capítulos como enfermedades respiratorias, circulatorias y digestivas, la participación extranjera se mantiene muy por debajo del peso observado en obstetricia, lo que refuerza que la sobrerrepresentación se concentra principalmente en prestaciones asociadas a maternidad y salud reproductiva.

B.2 Length of Stay & Severity

B.2.1 Length of stay by nationality

```
los_by_nat = (
    grd_com
    .groupby("nat_group")["los"]
    .agg(["mean", "median"])
    .reset_index()
)

los_by_nat["mean"] = los_by_nat["mean"].round(2)

print(los_by_nat)
```

```
  nat_group  mean  median
0   Chilean  7.08     3.0
1   Foreign  4.84     2.0
```

```
plot_los = grd_com[grd_com["los"] <= 30].copy()

plt.figure(figsize=(8, 5))

plot_los.boxplot(column="los", by="nat_group")

plt.title("Length of Stay by Nationality (LOS <= 30 days)")
plt.suptitle("")
plt.xlabel("Nationality group")
plt.ylabel("Length of stay (days)")

plt.tight_layout()
plt.show()
```

```
<Figure size 800x500 with 0 Axes>
```

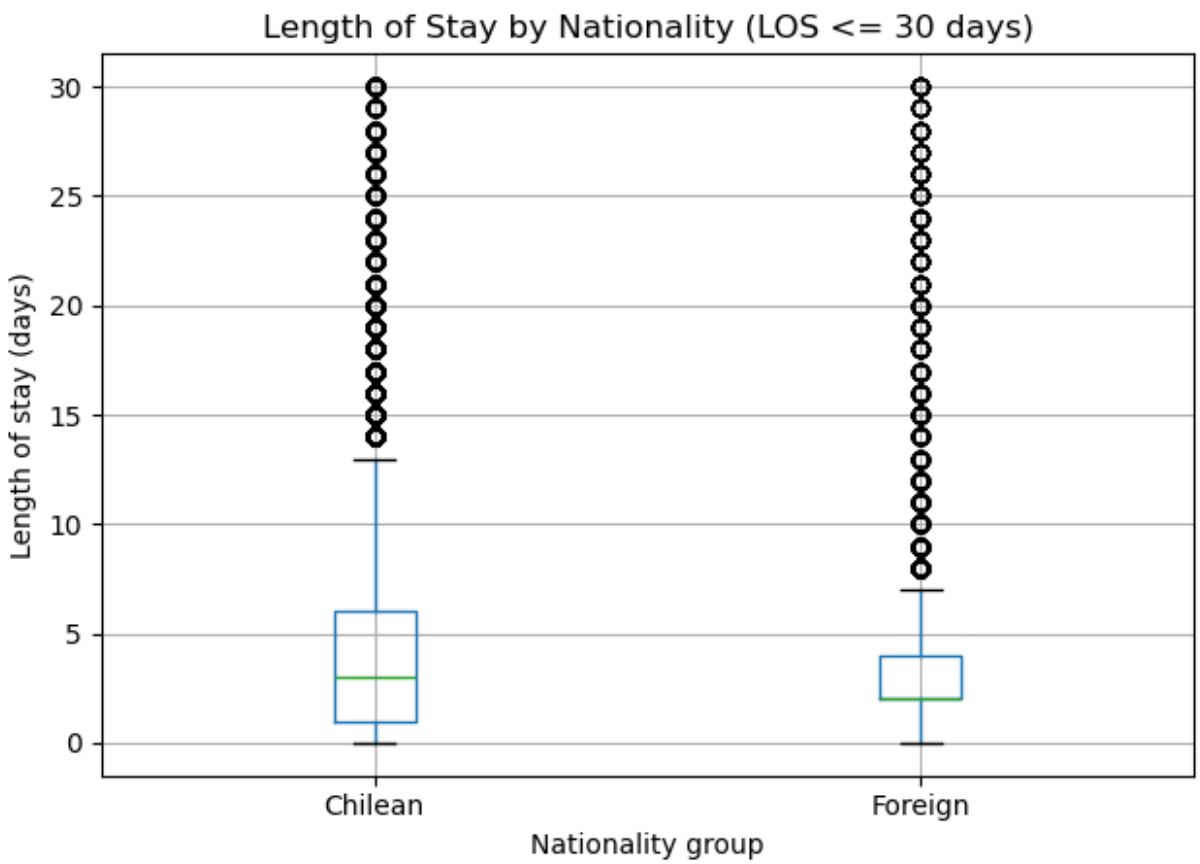

Se observan diferencias relevantes entre ambos grupos. Los pacientes chilenos presentan una estadía hospitalaria más larga que los extranjeros, tanto en promedio como en mediana. En particular, los chilenos registran un promedio de 7,08 días y una mediana de 3 días, mientras que los extranjeros presentan un promedio de 4,84 días y una mediana de 2 días.

Además, el boxplot muestra que la distribución de estadías entre chilenos es más dispersa y presenta una cola superior más extensa, lo que sugiere una mayor presencia de hospitalizaciones prolongadas. En cambio, los extranjeros muestran estadías más concentradas en valores bajos.

Por lo tanto, sí existen diferencias significativas en términos descriptivos: los pacientes chilenos tienden a permanecer más tiempo hospitalizados y exhiben una mayor variabilidad en la duración de la estadía.

B.2.2 Severity distribution

```
# Limpiar severidad
grd_com["IR_29301_SEVERIDAD"] = pd.to_numeric(
    grd_com["IR_29301_SEVERIDAD"],
    errors="coerce"
)

# Mapeo de etiquetas
severity_map = {
```

```
    0: "No severity",
    1: "Minor",
    2: "Moderate",
    3: "Major"
}

grd_com["severity_label"] =
grd_com["IR_29301_SEVERIDAD"].map(severity_map)

print("Severity distribution:")
print(grd_com["severity_label"].value_counts(dropna=False))
```

```
Severity distribution:
severity_label
Minor          13911
Major           8183
Moderate        7353
No severity     3679
Name: count, dtype: int64
```

```
severity_by_nat = (
    grd_com
    .groupby(["severity_label", "nat_group"])
    .size()
    .reset_index(name="discharges")
)

print(severity_by_nat)
```

```
  severity_label nat_group  discharges
0          Major   Chilean        7122
1          Major   Foreign        1061
2          Minor   Chilean        9699
3          Minor   Foreign        4212
4       Moderate   Chilean        5942
5       Moderate   Foreign        1411
6    No severity   Chilean        3216
7    No severity   Foreign         463
```

```
severity_pivot = (
    severity_by_nat
    .pivot(index="severity_label", columns="nat_group",
values="discharges")
    .fillna(0)
)

# Orden correcto
severity_order = ["No severity", "Minor", "Moderate", "Major"]
severity_pivot = severity_pivot.reindex(severity_order)

# Asegurar columnas
```

```python
for col in ["Chilean", "Foreign"]:
    if col not in severity_pivot.columns:
        severity_pivot[col] = 0

print(severity_pivot)
```

```
nat_group       Chilean  Foreign
severity_label
No severity        3216      463
Minor              9699     4212
Moderate           5942     1411
Major              7122     1061
```

```python
x = np.arange(len(severity_pivot.index))
width = 0.35

plt.figure(figsize=(9, 5))

plt.bar(
    x - width/2,
    severity_pivot["Chilean"],
    width=width,
    label="Chilean"
)

plt.bar(
    x + width/2,
    severity_pivot["Foreign"],
    width=width,
    label="Foreign"
)

plt.xticks(x, severity_pivot.index)
plt.xlabel("Severity level")
plt.ylabel("Number of discharges")
plt.title("Severity Distribution by Nationality")
plt.legend()
plt.grid(axis="y", alpha=0.25)
plt.tight_layout()
plt.show()
```

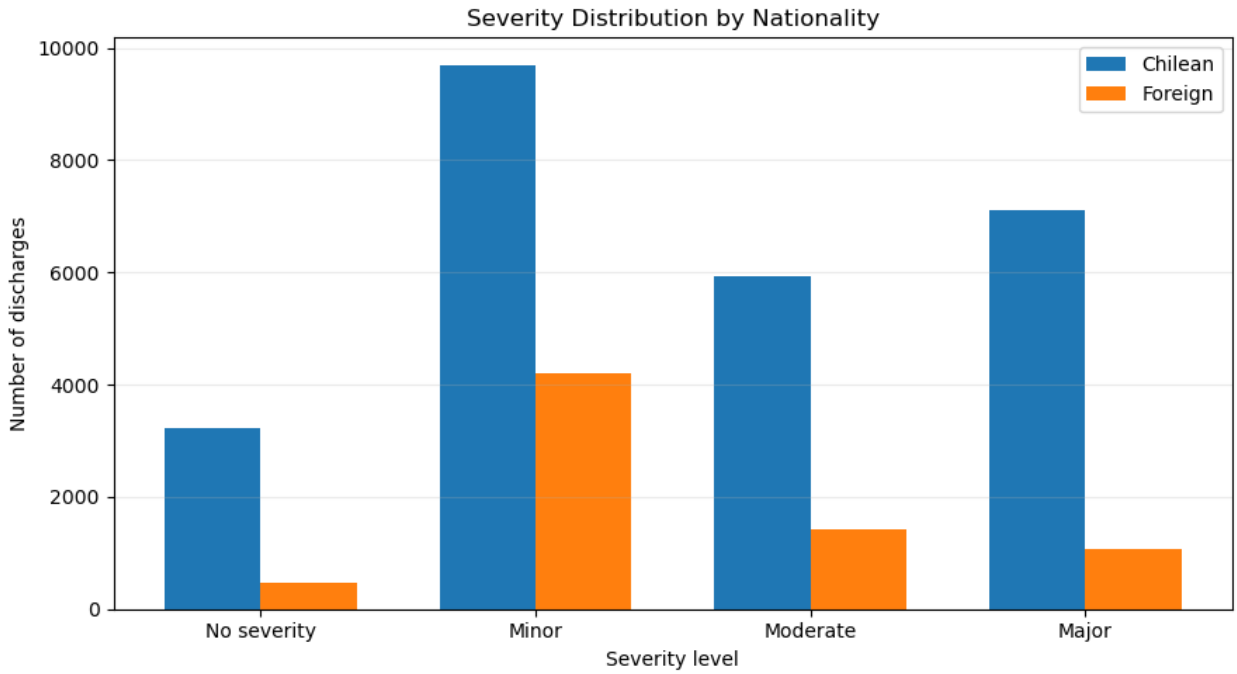

B.2.2 Distribución de Severidad y Días de Estadía (Length of Stay)

Al cruzar la severidad clínica de los egresos y los días de permanencia hospitalaria (LOS) con la nacionalidad, destacan las siguientes tendencias:

- **Concentración de la Gravedad:** Como se visualiza en el gráfico de barras, la inmensa mayoría de los ingresos de pacientes extranjeros se agrupa en los niveles de severidad más bajos (1 y 2). Por el contrario, la población chilena concentra una proporción y un volumen significativamente mayor de casos en los niveles de severidad 3 y 4 (mayor complejidad clínica, comorbilidades y riesgo).
- **Impacto en los Días de Estadía:** Esta diferencia en la gravedad clínica impacta directamente en el *Length of Stay*. Al hospitalizarse mayoritariamente por causas de baja severidad (como partos sin complicaciones), la población extranjera tiende a registrar estadías más cortas en comparación con la población chilena, quienes al ingresar por cuadros crónicos o severos requieren más días cama para su estabilización y recuperación.