Tarea 3: Cross-Dataset Ecological Modeling

Part 0: Building the Analytical Table

0.1 Class-pooled master table

```
import pandas as pd
from pathlib import Path
from IPython.display import display
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd


# Ruta a tu carpeta descargada
base_dir =
Path("/Users/ignaciorodriguezperez/Desktop/Preparacion_datos/files_exp
ort")

# Buscar TODOS los CSV (incluye subcarpetas)
all_csvs = list(base_dir.rglob("*.csv"))

print(f"Total archivos encontrados: {len(all_csvs)}")

# Separar por tipo
census_files = [p for p in all_csvs if "census_team" in p.name]
eno_files    = [p for p in all_csvs if "eno_team" in p.name]
grd_files    = [p for p in all_csvs if "grd_team" in p.name]

print(f"Census: {len(census_files)}")
print(f"ENO: {len(eno_files)}")
print(f"GRD: {len(grd_files)}")
```

```
Total archivos encontrados: 63
Census: 21
ENO: 21
GRD: 21
```

```
census_master = pd.concat([pd.read_csv(p) for p in census_files],
ignore_index=True)
eno_master    = pd.concat([pd.read_csv(p) for p in eno_files],
ignore_index=True)
grd_master    = pd.concat([pd.read_csv(p) for p in grd_files],
ignore_index=True)

display(census_master)
```

```
    codigo_comuna        nombre_comuna  pop_total  pop_chilean
pop_foreign  \
0           13103          Cerro Navia   126140.0     113911.0
12229.0
1           13121  Pedro Aguirre Cerda    95390.0      86292.0
9098.0
2           13132             Vitacura    85502.0      78906.0
6596.0
3           13301               Colina   173293.0     149378.0
22498.0
4           13501            Melipilla   136325.0     124407.0
11069.0
5           13601            Talagante    76429.0      71322.0
4559.0
6           13105            El Bosque   155257.0     143714.0
10652.0
7           13116            Lo Espejo    87295.0      80266.0
6512.0
8           13202               Pirque    29060.0      28398.0
442.0
9           13603        Isla de Maipo    39274.0      37775.0
1332.0
10          13115         Lo Barnechea   112620.0      98589.0
12198.0
11          13128                Renca   143622.0     130218.0
12523.0
12          13402                 Buin   116969.0     110229.0
5960.0
13          13104             Conchalí   121587.0     103271.0
17686.0
14          13109          La Cisterna   103157.0      82209.0
19762.0
15          13126        Quinta Normal   129351.0      92347.0
35630.0
16          13123          Providencia   143974.0     126841.0
17133.0
17          13130           San Miguel   150829.0     110161.0
40668.0
18          13404                Paine    78828.0      72865.0
5963.0
19          13107           Huechuraba   101808.0      92790.0
8381.0
20          13112           La Pintana   175421.0     166483.0
7732.0
21          13502                Alhué     7768.0       6871.0
879.0
22          13504          María Pinto    15352.0      14996.0
319.0
23          13602             El Monte    37497.0      36404.0
915.0
```

```
24          13108        Independencia   116943.0      64272.0
51908.0
25          13127             Recoleta   154615.0     118968.0
34009.0
26          13505            San Pedro    11108.0       9808.0
1260.0
27          13604        Padre Hurtado    81243.0      75497.0
5296.0
28          13117             Lo Prado    91290.0      78678.0
12110.0
29          13124             Pudahuel   227820.0     210831.0
15344.0
30          13111            La Granja   112022.0     101705.0
9550.0
31          13118                Macul   123800.0     105336.0
17497.0
32          13131            San Ramón    76002.0      69248.0
6214.0
33          13401         San Bernardo   306371.0     284663.0
19544.0
34          13403      Calera de Tango    25491.0      24430.0
898.0
35          13119                maipu   500600.0     469627.0
30973.0
36          13102            Cerrillos    85041.0      71466.0
12732.0
37          13105     Estación Central   155257.0     142967.0
11347.0
38          13302                Lampa   145160.0     125486.0
18608.0
39          13122            Peñalolén   236478.0     216664.0
18304.0
40          13605             Peñaflor    94402.0      90616.0
3235.0
41          13201          Puente Alto   564477.0     534717.0
29760.0
42           5101           Valparaíso   284938.0     272618.0
12320.0
43           5102           Casablanca    29876.0      27607.0
2269.0
44          13114           LAS CONDES   292739.0     261670.0
31069.0
45          13503             CURACAVÍ    34977.0      33517.0
1460.0
46          13109             La Reina   103157.0      82209.0
19762.0
47          13122            Quilicura   236478.0     214770.0
20141.0
48          13125               Tiltil   205624.0     177098.0
27310.0
```

```
49          13101             Santiago     5806.0     258429.0
176956.0
50          13120                Ñuñoa   241467.0     239323.0
0.0
51          13129          San Joaquín    95602.0      95039.0
0.0
52          13203    San José de Maipo    17441.0      17303.0
0.0
53          13110           La Florida   374836.0     335340.0
36685.0

    pct_foreign  median_age_chilean  median_age_foreign  \
0      9.694784                38.0                32.0
1      9.537687                41.0                32.0
2      7.714439                39.0                43.0
3     13.090000                33.0                35.0
4      8.170000                37.0                30.0
5      6.010000                36.0                32.0
6      6.860882                37.0                31.0
7      7.459763                38.0                32.0
8      1.520991                37.0                40.0
9      3.391557                37.0                31.0
10    10.831113                34.0                42.0
11     8.719416                35.0                33.0
12     5.095367                34.0                34.0
13    14.545963                39.0                34.0
14    19.157207                37.0                32.0
15    27.545206                38.0                32.0
16    11.900065                38.0                39.0
17    26.962985                36.0                33.0
18     7.564571                36.0                31.0
19     8.280000                36.0                35.0
20     4.440000                34.0                32.0
21    11.340000                37.0                28.0
22     2.080000                38.0                31.0
23     2.450000                36.0                34.0
24    44.387437                36.0                33.0
25    21.995925                39.0                34.0
26    11.343176                40.0                29.0
27     6.518715                34.0                33.0
28    13.265418                41.0                34.0
29     6.735142                37.0                33.0
30     8.525111                39.0                32.0
31    14.133279                39.0                35.0
32     8.176101                40.0                32.0
33     6.380000                34.0                33.0
34     3.520000                37.0                35.0
35     6.190000                38.0                34.0
36    15.000000                36.0                34.0
37     7.300000                37.0                32.0
```

```
38    12.800000                32.0                33.0
39     7.740255                38.0                34.0
40     3.426834                36.0                34.0
41     5.272137                35.0                34.0
42     4.320000                36.8                30.1
43     7.590000                34.5                28.7
44    10.613208                38.0                40.0
45     4.174172                38.0                35.0
46    19.380000                37.0                32.0
47     8.570000                38.0                35.0
48    13.360000                34.0                34.0
49  3047.812608                35.0                34.0
50     0.000000                37.0                 NaN
51     0.000000                38.0                 NaN
52     0.000000                39.0                 NaN
53     9.786947                38.0                34.0

    mean_schooling_chilean  mean_schooling_foreign
emp_rate_chilean  \
0                10.307062               11.639354          0.577341

1                11.227268               11.518868          0.611082

2                16.362464               15.912903          0.702362

3                12.610000               12.780000         59.950000

4                11.070000               11.260000         58.930000

5                11.830000               12.260000         59.750000

6                10.971926               12.114083         58.937127

7                10.356598               11.212395         56.828001

8                12.411691               13.803815         65.068493

9                11.147838               12.256439         59.301640

10               14.868803               15.031679         63.152090

11               10.895060               12.027874         61.276611

12               12.185436               13.374942         63.132818

13               11.325066               11.983653          0.610039

14               12.724804               13.401107          0.674023

15               11.942872               12.615201          0.655335
```

16	16.475442	16.348022	76.790024
17	14.316606	14.617748	73.221801
18	11.101813	11.780656	60.775207
19	12.770000	14.120000	63.920000
20	10.010000	11.470000	55.710000
21	10.600000	11.380000	63.780000
22	10.600000	11.460000	61.080000
23	10.900000	12.530000	60.750000
24	12.854490	12.936711	67.161443
25	11.617627	11.922532	62.599410
26	9.734945	9.659767	60.402906
27	12.115748	13.170452	65.168933
28	11.056758	12.004300	0.625905
29	11.692555	12.441822	0.619386
30	10.856734	12.150499	59.357184
31	13.336334	14.598976	69.140360
32	10.520867	11.916823	60.325979
33	11.600000	12.240000	60.810000
34	11.970000	12.040000	60.390000
35	12.640000	12.980000	62.550000
36	11.725000	11.439000	60.800000
37	10.960000	12.194000	58.800000
38	12.165000	12.308000	64.700000
39	12.222864	12.847696	64.719587
40	11.981959	12.994343	59.739163
41	12.119722	12.678511	62.399903

42	11.400000	11.900000	53.900000
43	10.800000	10.300000	56.400000
44	15.967253	16.103878	69.122625
45	11.494170	13.097132	60.375991
46	12.910000	13.560000	67.500000
47	12.190000	13.060000	64.600000
48	12.170000	12.350000	62.100000
49	14.421518	13.805328	72.658632
50	15.706700	NaN	77.334300
51	12.039900	NaN	65.721900
52	12.307200	NaN	65.077900
53	12.846742	13.965309	65.992957

	emp_rate_foreign	dependency_ratio
0	0.697697	0.477499
1	0.720027	0.523315
2	0.809768	0.576132
3	70.000000	45.820000
4	74.380000	50.480000
5	69.740000	46.760000
6	71.021600	0.497001
7	68.394742	0.497624
8	77.715877	0.481368
9	72.289157	0.475634
10	73.112093	45.969697
11	72.134725	47.257795
12	72.907216	46.352114
13	0.751039	0.478603
14	0.787796	0.447939
15	0.781131	0.434953
16	81.550877	38.775471
17	80.639469	37.187113
18	67.073427	47.587576
19	75.800000	44.000000
20	67.680000	49.000000
21	77.520000	51.000000
22	69.200000	52.000000
23	69.140000	50.000000
24	80.378062	39.835464

```
25          76.930213          45.127984
26          75.824176          56.826204
27          73.954023          45.120840
28           0.754180           0.475465
29           0.738583           0.428643
30          72.139429          49.864212
31          81.189070          44.132816
32          73.826821          49.669161
33          71.160000          45.280000
34          72.700000          45.970000
35          73.510000          43.270000
36          69.500000           0.463000
37          71.700000           0.497000
38          72.700000           0.446000
39          77.567496          43.493061
40          70.507440          46.112771
41          71.870457          43.030221
42          63.200000          46.980000
43          71.800000          44.210000
44          80.116844          47.119811
45          70.323129          50.322331
46          78.900000          44.800000
47          77.800000          43.500000
48          74.000000          38.500000
49          83.340478          26.210683
50                NaN          38.337700
51                NaN          47.177400
52                NaN          48.459300
53          78.785794          46.806252
```

```
display(eno_master )
```

```
    codigo_comuna        nombre_comuna  eno_total  eno_chilean
eno_foreign  \
0           13301               Colina       1259          576
174
1           13501            Melipilla        824          387
245
2           13601            Talagante        314          186
32
3           13105            El Bosque       1212          634
111
4           13116            Lo Espejo        678          366
72
5           13202               Pirque        136           76
8
6           13603        Isla de Maipo        115           67
11
7           13103           Cerro Navia       1002          565
127
```

8	13121	Pedro Aguirre Cerda	910	452	102
9	13132	Vitacura	538	238	50
10	13104	Conchalí	1134	635	188
11	13109	La Cisterna	714	333	149
12	13126	Quinta Normal	1361	572	431
13	13115	Lo Barnechea	630	278	42
14	13128	Renca	1064	590	113
15	13402	Buin	551	251	34
16	13123	Providencia	1455	1001	239
17	13130	San Miguel	1249	587	330
18	13404	Paine	390	185	74
19	13112	La Pintana	1507	755	102
20	13107	Huechuraba	832	456	68
21	13602	El Monte	146	93	18
22	13502	Alhué	28	14	9
23	13504	María Pinto	32	24	4
24	13108	Independencia	1642	607	786
25	13127	Recoleta	1978	964	501
26	13505	San Pedro	731	19	19
27	13604	Padre Hurtado	337	206	44
28	13117	Lo Prado	591	442	149
29	13124	Pudahuel	1051	882	169
30	13111	La Granja	943	454	108
31	13118	Macul	890	405	110
32	13131	San Ramón	687	359	

```
54
33          13401         San Bernardo       2172         1129
149
34          13403      Calera de Tango         84           62
11
35          13119                maipu       3316         1827
267
36          13102            Cerrillos        642          297
101
37          13105     Estación Central       1212          634
111
38          13302                Lampa        672          390
93
39          13122            Peñalolén       1487          701
124
40          13605             Peñaflor        441          251
32
41          13201          Puente Alto       4334         2527
280
42           5101           Valparaíso       4821         4312
421
43           5102           Casablanca        312          278
29
44          13114           LAS CONDES       2123          970
231
45          13503             CURACAVÍ        165          107
14
46          13109             La Reina        714          333
149
47          13122            Quilicura       1487          701
124
48          13125               Tiltil       1592          769
270
49          13101             Santiago      12186         5059
3635
50          13120                Ñuñoa       1735          830
255
51          13129          San Joaquín        767          372
161
52          13203    San José de Maipo         92           51
11
53          13110           La Florida       2128         1539
342

    eno_desconocido                                   eno_top3_diseases
\
0               509                         Parotiditis | VIH | Sifilis

1               192                          VIH | Chagas | Parotiditis
```

2	96	VIH | Parotiditis | Chagas
3	467	VIH, Parotiditis, Coqueluche
4	240	VIH, Parotiditis, Coqueluche
5	52	VIH, Parotiditis, Chagas
6	37	VIH, Parotiditis, Sifilis
7	310	VIH, Coqueluche, Parotiditis
8	356	VIH, Parotiditis, Coqueluche
9	250	Parotiditis, VIH, Coqueluche
10	311	VIH | Parotiditis | Sifilis
11	232	VIH | Parotiditis | Coqueluche
12	358	VIH | Parotiditis | Sifilis
13	310	Parotiditis | Coqueluche | VIH
14	361	VIH | Parotiditis | Coqueluche
15	266	Parotiditis | VIH | Coqueluche
16	215	VIH | Sifilis | Parotiditis
17	332	VIH | Parotiditis | Sifilis
18	131	VIH | Parotiditis | Coqueluche
19	650	VIH | Parotiditis | Coqueluche
20	308	VIH | Parotiditis | Sifilis
21	35	VIH | Parotiditis | Sifilis
22	5	Chagas | VIH | Parotiditis
23	4	VIH | Parotiditis | Chagas
24	0	Dato Faltante
25	0	Dato Faltante
26	0	Dato Faltante
27	0	Dato Faltante

28	0	VIH, Sifilis, Parotiditis
29	0	VIH, Sifilis, Parotiditis
30	381	VIH | Parotiditis | Coqueluche
31	375	VIH | Parotiditis | Coqueluche
32	274	VIH | Parotiditis | Coqueluche
33	894	PAROTIDITIS, SIN COMPLICACIONES, no aplica, TO...
34	11	no aplica, PAROTIDITIS, SIN COMPLICACIONES, HE...
35	1222	VIH | Parotiditis | Coqueluche
36	244	VIH | Parotiditis | Sifilis
37	467	VIH | Parotiditis | Coqueluche
38	189	VIH | Parotiditis | Sifilis
39	662	VIH | Parotiditis | Coqueluche
40	158	VIH | Parotiditis | Coqueluche
41	1527	VIH | Parotiditis | Coqueluche
42	88	Sífilis | VIH | Tuberculosis
43	5	Sífilis | Coqueluche | VIH
44	922	VIH | Parotiditis | Sifilis
45	44	VIH | Sifilis | Parotiditis
46	232	VIH | Parotiditis | Coqueluche
47	662	VIH | Parotiditis | Coqueluche
48	553	VIH | Parotiditis | Coqueluche
49	3492	VIH | Parotiditis | Sifilis
50	650	VIH | Parotiditis | Coqueluche
51	234	VIH | Parotiditis | Coqueluche
52	30	VIH | Parotiditis | Coqueluche
53	247	VIH | Sifilis | Parotiditis

```
    eno_rate_per_10k
0          72.650000
1          60.440000
2          41.080000
3          78.064113
4          77.667679
5          46.799725
6          29.281458
7          79.435548
8          95.397840
9          62.922505
10         93.266550
11         69.214886
12        105.217586
13         55.940000
14         74.080000
15         47.110000
16         92.240000
17        115.700000
18         53.600000
19         85.907617
20         81.722458
21         38.936448
22         36.045314
23         20.844190
24        156.380952
25        104.105263
26        609.166667
27         51.846154
28         64.738745
29         46.132912
30         84.179893
31         71.890145
32         90.392358
33         70.894438
34         32.952807
35         66.240000
36         75.490000
37         78.060000
38         46.290000
39         62.880000
40         46.720000
41         76.779036
42        169.190000
43        104.430000
44         72.521900
45         47.173900
46         69.210000
```

```
47         62.880000
48         77.420000
49      20988.632449
50         71.852500
51         80.228400
52         52.749300
53         56.771495
```

```
display(grd_master)
```

```
    codigo_comuna        nombre_comuna  grd_total  grd_chilean
grd_foreign  \
0           13105            El Bosque       9517         9046
471
1           13603        Isla de Maipo       2059         1989
70
2           13116            Lo Espejo       5269         4949
320
3           13202               Pirque       1731         1702
29
4           13301               Colina      14742        12697
2045
5           13501            Melipilla      29404        26882
2522
6           13601            Talagante      12342        11754
588
7           13103          Cerro Navia      27846        25523
2323
8           13121  Pedro Aguirre Cerda      15537        14355
1182
9           13132             Vitacura       1790         1550
240
10          13104             Conchalí      10561         9346
1215
11          13109          La Cisterna       7338         6249
1089
12          13126        Quinta Normal      14588        11624
2964
13          13402                 Buin      15457        14669
788
14          13115         Lo Barnechea       6883         6204
679
15          13128                Renca      25748        24002
1746
16          13404                Paine      11428        10437
991
17          13123          Providencia      10505         9451
1054
18          13130           San Miguel      13853        11077
2776
```

```
19          13502                Alhué        900          793
107
20          13602             El Monte       4114         4015
99
21          13107           Huechuraba       6170         5743
427
22          13112           La Pintana      25556        24778
778
23          13504          María Pinto       1683         1630
53
24          13108        Independencia      10573            0
0
25          13604        Padre Hurtado       4764            0
0
26          13127             Recoleta      13435            0
0
27          13505            San Pedro       1355            0
0
28          13117             Lo Prado       6169         5596
573
29          13124             Pudahuel      10910        10189
721
30          13111            La Granja      14803        13943
860
31          13118                Macul      13343        12128
1215
32          13131            San Ramón      11743        10986
757
33          13403      Calera de Tango       1539         1502
37
34          13401         San Bernardo      44506        42580
1926
35          13119                maipu      62614        58932
3682
36          13102            Cerrillos       7623         6681
942
37          13105     Estación Central      17446        12314
5132
38          13302                Lampa       8057         6984
1073
39          13122            Peñalolén      44917        42047
2870
40          13605             Peñaflor      10357         9981
376
41          13201          Puente Alto      39492        38156
1336
42           5101           Valparaíso      24180        22541
1639
43           5102           Casablanca       2134         1963
```

```
171
44          13114           LAS CONDES      10656         9651
1005
45          13503             CURACAVÍ       5216         5064
152
46          13109             La Reina       5004         4692
312
47          13122            Quilicura      13062        11120
1942
48          13125               Tiltil       1435         1360
75
49          13101             Santiago      54929        35664
19265
50          13120                Ñuñoa      17291        15769
1522
51          13129          San Joaquín      12206        11098
1108
52          13203    San José de Maipo       2844         2781
63
53          13110           La Florida      49846        46736
3110

    grd_pct_foreign  grd_mean_los  grd_mean_los_chilean
grd_mean_los_foreign  \
0          4.949039      7.223915              7.369335
4.430998
1          3.399709      5.699854              5.733534
4.742857
2          6.073259      6.763143              6.819357
5.893750
3          1.675332      4.176776              4.157462
5.310345
4         13.870000      5.880000              6.060000
4.720000
5          8.580000      4.980000              5.090000
3.890000
6          4.760000      6.460000              6.530000
5.090000
7          8.342311      6.379049              6.487639
5.185966
8          7.607646      6.553517              6.672309
5.110829
9         13.407821      5.186034              5.393548
3.845833
10         0.115046      6.366632              6.616413
4.445267
11         0.148406      6.360998              6.642663
4.744720
12         0.203181      6.291952              6.686683
```

```
4.743927
13          5.100000      5.576291              5.603302
5.086142
14          9.860000      5.166742              5.239609
4.483568
15          6.780000      6.392185              6.495590
4.999133
16          8.670000      5.570000              5.660000
4.650000
17         10.030000      5.850000              5.920000
5.190000
18         20.040000      6.370000              6.740000
4.910000
19         11.890000      5.640000              5.800000
4.460000
20          2.410000      5.950000              5.980000
4.660000
21          6.920000      6.090000              6.220000
4.270000
22          3.040000      5.370000              5.420000
3.860000
23          3.150000      4.780000              4.830000
3.110000
24          0.000000      6.467890              0.000000
0.000000
25          0.000000      6.111881              0.000000
0.000000
26          0.000000      6.329066              0.000000
0.000000
27          0.000000      4.900369              0.000000
0.000000
28          9.288377      5.955584              6.083631
4.705061
29          6.608616      6.026123              6.160762
4.123440
30          5.809633      5.393569              5.440436
4.633721
31          9.105898      5.520947              5.670679
4.026337
32          6.446394      4.966448              5.019843
4.191546
33          2.400000      7.220000              7.240000
6.430000
34          4.330000      6.010000              6.040000
5.520000
35          5.880000      7.020000              7.160000
4.680000
36         12.360000      7.390000              7.710000
5.110000
```

```
37        29.420000      6.530000              7.220000
4.870000
38        13.320000      5.990000              6.230000
4.470000
39         6.390000      5.340000              5.430000
4.140000
40         3.630000      6.140000              6.170000
5.430000
41         3.382964      4.784390              4.790312
4.615269
42         6.780000      5.600000              5.700000
4.900000
43         8.010000      4.800000              4.900000
4.100000
44         9.430000      5.920000              6.130000
3.790000
45         2.910000      6.490000              6.540000
4.820000
46         6.240000      5.380000              5.480000
3.850000
47        14.870000      5.900000              6.170000
4.400000
48         5.230000      6.310000              6.400000
4.750000
49        35.072548      6.682745              7.682129
4.817208
50         8.802300     20.967200             21.215300
18.396800
51         9.077500     23.594800             23.475900
24.785200
52         2.215200     18.848100             18.766600
22.444400
53         6.239217      6.002898              6.132362
4.133389

    grd_mean_severity  grd_mortality_rate  \
0            1.774614            3.425449
1            1.619233            1.602720
2            1.626684            2.770924
3            1.496245            2.541883
4            1.410000            2.040000
5            1.230000            2.230000
6            1.630000            2.600000
7            1.476765            3.372118
8            1.615434            3.617172
9            1.301117            2.458101
10           1.429505            0.036834
11           1.610793            0.037885
12           1.452838            0.033178
```

```
13            1.488646             2.956589
14            1.425977             1.772483
15            1.464696             3.068199
16            1.460000             3.010000
17            1.430000             2.930000
18            1.590000             3.350000
19            1.280000             2.333000
20            1.620000             2.552000
21            1.370000             3.420000
22            1.470000             1.953000
23            1.200000             1.664000
24            0.000000             2.856332
25            0.000000             1.910160
26            0.000000             2.977298
27            0.000000             1.549815
28            1.383804             3.063706
29            1.483220             2.722273
30            1.482875             2.526515
31            1.569962             3.440006
32            1.453802             2.214085
33            1.750000             2.600000
34            1.470000             2.350000
35            1.640000             3.490000
36            1.700000             3.270000
37            1.650000             2.720000
38            1.420000             2.020000
39            1.560000             2.910000
40            1.390000             1.890000
41            1.510167             2.248557
42            1.920000             2.840000
43            1.780000             2.150000
44            1.430000             2.930000
45            1.400000             2.930000
46            1.382000             2.618000
47            1.393000             2.167000
48            1.348000             3.345000
49            1.615485             2.799978
50            1.375700             2.961100
51            1.556800             3.252500
52            1.413200             1.406500
53            1.403522             2.999238

                                       grd_top3_chapters
grd_rate_per_10k
0   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...
612.983634
1   Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
524.265417
2   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...
```

```
603.585543
3   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...
595.664143
4   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
850.700000
5   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
2156.900000
6   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1614.830000
7   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...
2207.547170
8   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...
1628.787085
9   Cap.02  NEOPLASIAS (C00-D49), Cap.07  ENFERMED...
209.351828
10  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
868.596149
11  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
711.342905
12  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1127.784091
13  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
1321.461242
14  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
611.170307
15  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1792.761555
16  Cálculo de la vesícula biliar sin colecistitis...
1570.660000
17  Catarata | no especificada | Cálculo de la ves...
665.930000
18  Catarata | no especificada | Apendicitis aguda...
1283.230000
19  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1158.600000
20  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1097.200000
21  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
606.000000
22  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1456.800000
23  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1096.300000
24                                      Dato Faltante
1006.952381
25                                      Dato Faltante
732.923077
26                                      Dato Faltante
707.105263
```

```
27                                        Dato Faltante
1129.166667
28  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
675.758572
29  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
478.886840
30  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
1321.436861
31  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
1077.786753
32  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
1545.090919
33  LESIONES TRAUMÁTICAS, ENVENENAMIENTOS Y OTRAS ...
603.740000
34  EMBARAZO, PARTO Y PUERPERIO, ENFERMEDADES DEL ...
1452.680000
35  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
1250.780000
36  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
896.390000
37  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
1123.690000
38  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
555.040000
39  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
1899.420000
40  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
1097.120000
41  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
699.621065
42  Embarazo y parto | Enfermedades circulatorias ...
848.610000
43  Embarazo y parto | Enfermedades digestivas | E...
714.290000
44  Cap.02  NEOPLASIAS (C00-D49) | Cap.19  LESIONE...
359.840000
45  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
1483.290000
46  Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K0...
485.090000
47  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
552.360000
48  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
69.790000
49  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
94607.302790
50                                     H26 | K80 | K35
716.081300
51                                     H26 | K80 | K35
1276.751500
```

```
52                                      H26 | K80 | K35
1630.640400
53                                H25.9 | K80.2 | Z51.1
1329.808236
```

```python
# Chequeamos si hay comunas unicas
for name, df in [("census", census_master), ("eno", eno_master),
("grd", grd_master)]:
    print(f"{name.upper()}:")
    print("Filas:", len(df))
    print("Comunas únicas:", df["codigo_comuna"].nunique())
    print("-"*30)
```

```
CENSUS:
Filas: 54
Comunas únicas: 51
------------------------------
ENO:
Filas: 54
Comunas únicas: 51
------------------------------
GRD:
Filas: 54
Comunas únicas: 51
------------------------------
```

Check 1: Filas vs comunas únicas

Se comparó el número de filas con el número de comunas únicas ("codigo_comuna") en cada tabla maestra.

Resultados:

- Census: 54 filas vs 51 comunas únicas
- ENO: 54 filas vs 51 comunas únicas
- GRD: 54 filas vs 51 comunas únicas

Los valores no coinciden, lo que indica la presencia de duplicados en las tablas maestras.

En particular, existen 3 comunas duplicadas en cada tabla. Esto sugiere inconsistencias en los datos al unir los trabajos de todos los equipos, probablemente debido a errores en la asignación de "codigo_comuna" o en el mapeo entre código y nombre de comuna.

```python
census_set = set(census_master["codigo_comuna"])
eno_set    = set(eno_master["codigo_comuna"])
grd_set    = set(grd_master["codigo_comuna"])

print("En census pero no en ENO:", census_set - eno_set)
print("En census pero no en GRD:", census_set - grd_set)
```

```
print("En ENO pero no en census:", eno_set - census_set)
print("En GRD pero no en census:", grd_set - census_set)
```

```
En census pero no en ENO: set()
En census pero no en GRD: set()
En ENO pero no en census: set()
En GRD pero no en census: set()
```

Check 2: Asimetrías entre tablas

Se compararon los conjuntos de "codigo_comuna" entre las tres tablas maestras.

Resultados:

- Comunas en census pero no en ENO: vacío
- Comunas en census pero no en GRD: vacío
- Comunas en ENO pero no en census: vacío
- Comunas en GRD pero no en census: vacío

No se detectaron asimetrías entre las tablas. Todas las comunas presentes en una tabla también aparecen en las otras.

Esto indica que el conjunto de comunas es consistente entre los tres datasets (census, ENO y GRD).

Por lo tanto, los problemas observados anteriormente se deben a duplicación de filas y no a ausencia de comunas.

```
MY_COMUNAS = [13102, 13105, 13302]
for name, df in [("census", census_master), ("eno", eno_master),
("grd", grd_master)]:
    print(f"\n{name.upper()}:")
    print(df[df["codigo_comuna"].isin(MY_COMUNAS)])
```

```
CENSUS:
    codigo_comuna     nombre_comuna  pop_total  pop_chilean
pop_foreign  \
6           13105         El Bosque   155257.0     143714.0
10652.0
36          13102         Cerrillos    85041.0      71466.0
12732.0
37          13105  Estación Central   155257.0     142967.0
11347.0
38          13302             Lampa   145160.0     125486.0
18608.0

    pct_foreign  median_age_chilean  median_age_foreign  \
6      6.860882                37.0                31.0
36    15.000000                36.0                34.0
```

```
37     7.300000                37.0                32.0
38    12.800000                32.0                33.0

    mean_schooling_chilean  mean_schooling_foreign
emp_rate_chilean  \
6                10.971926               12.114083         58.937127

36               11.725000               11.439000         60.800000

37               10.960000               12.194000         58.800000

38               12.165000               12.308000         64.700000


    emp_rate_foreign  dependency_ratio
6            71.0216          0.497001
36           69.5000          0.463000
37           71.7000          0.497000
38           72.7000          0.446000

ENO:
    codigo_comuna     nombre_comuna  eno_total  eno_chilean
eno_foreign  \
3           13105         El Bosque       1212          634
111
36          13102         Cerrillos        642          297
101
37          13105  Estación Central       1212          634
111
38          13302             Lampa        672          390
93

    eno_desconocido               eno_top3_diseases  eno_rate_per_10k

3               467    VIH, Parotiditis, Coqueluche         78.064113

36              244     VIH | Parotiditis | Sifilis         75.490000

37              467  VIH | Parotiditis | Coqueluche         78.060000

38              189     VIH | Parotiditis | Sifilis         46.290000


GRD:
    codigo_comuna     nombre_comuna  grd_total  grd_chilean
grd_foreign  \
0           13105         El Bosque       9517         9046
471
36          13102         Cerrillos       7623         6681
942
37          13105  Estación Central      17446        12314
```

```
5132
38          13302             Lampa       8057         6984
1073

    grd_pct_foreign  grd_mean_los  grd_mean_los_chilean
grd_mean_los_foreign  \
0          4.949039      7.223915              7.369335
4.430998
36        12.360000      7.390000              7.710000
5.110000
37        29.420000      6.530000              7.220000
4.870000
38        13.320000      5.990000              6.230000
4.470000

    grd_mean_severity  grd_mortality_rate  \
0            1.774614            3.425449
36           1.700000            3.270000
37           1.650000            2.720000
38           1.420000            2.020000

                                     grd_top3_chapters
grd_rate_per_10k
0   Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...
612.983634
36  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
896.390000
37  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
1123.690000
38  Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
555.040000
```

Check 3: Validación de mis comunas

Se revisaron las comunas del equipo (13102, 13105, 13302) en las tres tablas maestras como es solicitado, los resultados son:

- 13102 (Cerrillos): aparece una sola vez en todas las tablas y los valores coinciden con los obtenidos en Tarea 1 y Tarea 2.
- 13302 (Lampa): aparece una sola vez en todas las tablas y los valores coinciden con los resultados previamente calculados.
- 13105: aparece duplicada en las tres tablas con dos nombres distintos:
  - "El Bosque"
  - "Estación Central"

Además, los valores asociados a cada fila son distintos, lo que indica un error en los datos.

Se utilizará la versión consistente con los resultados de Tarea 1 y Tarea 2 entregados por el equipo, es decir, la fila correspondiente a "Estación Central", y se descartará la fila incorrecta. Esto asegura coherencia con el trabajo previamente validado y evita incorporar datos erróneos en los análisis posteriores.

```
## Se realiza la limpieza final de los datos
correct_names = {
    13102: "Cerrillos",
    13105: "Estación Central",
    13302: "Lampa",
    13109: "La Cisterna",
    13122: "Quilicura"
}

def clean_master(df):
    return df[
        df.apply(
            lambda row: correct_names.get(row["codigo_comuna"],
row["nombre_comuna"]) == row["nombre_comuna"],
            axis=1
        )
    ].copy()

census_clean = clean_master(census_master)
eno_clean    = clean_master(eno_master)
grd_clean    = clean_master(grd_master)

for name, df in [("census", census_clean), ("eno", eno_clean), ("grd",
grd_clean)]:
    print(f"\n{name.upper()}:")
    print("Filas:", len(df))
    print("Comunas únicas:", df["codigo_comuna"].nunique())
```

```
CENSUS:
Filas: 51
Comunas únicas: 51

ENO:
Filas: 51
Comunas únicas: 51

GRD:
Filas: 51
Comunas únicas: 51
```

0.2 Merge on codigo_comuna

```
## merge y validación final
df_final = census_clean.merge(
```

```
    eno_clean,
    on=["codigo_comuna", "nombre_comuna"],
    how="inner"
)

df_final = df_final.merge(
    grd_clean,
    on=["codigo_comuna", "nombre_comuna"],
    how="inner"
)

print(df_final.shape)
df_final.head()
```

```
(51, 30)

   codigo_comuna        nombre_comuna  pop_total  pop_chilean
pop_foreign  \
0          13103          Cerro Navia   126140.0     113911.0
12229.0
1          13121  Pedro Aguirre Cerda    95390.0      86292.0
9098.0
2          13132             Vitacura    85502.0      78906.0
6596.0
3          13301               Colina   173293.0     149378.0
22498.0
4          13501            Melipilla   136325.0     124407.0
11069.0

   pct_foreign  median_age_chilean  median_age_foreign  \
0     9.694784                38.0                32.0
1     9.537687                41.0                32.0
2     7.714439                39.0                43.0
3    13.090000                33.0                35.0
4     8.170000                37.0                30.0

   mean_schooling_chilean  mean_schooling_foreign  ...  grd_chilean  \
0               10.307062               11.639354  ...        25523
1               11.227268               11.518868  ...        14355
2               16.362464               15.912903  ...         1550
3               12.610000               12.780000  ...        12697
4               11.070000               11.260000  ...        26882

   grd_foreign  grd_pct_foreign  grd_mean_los  grd_mean_los_chilean  \
0         2323         8.342311      6.379049              6.487639
1         1182         7.607646      6.553517              6.672309
2          240        13.407821      5.186034              5.393548
3         2045        13.870000      5.880000              6.060000
4         2522         8.580000      4.980000              5.090000
```

```
   grd_mean_los_foreign  grd_mean_severity grd_mortality_rate  \
0              5.185966           1.476765           3.372118
1              5.110829           1.615434           3.617172
2              3.845833           1.301117           2.458101
3              4.720000           1.410000           2.040000
4              3.890000           1.230000           2.230000

                                  grd_top3_chapters  grd_rate_per_10k

0  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...       2207.547170

1  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...       1628.787085

2  Cap.02  NEOPLASIAS (C00-D49), Cap.07  ENFERMED...        209.351828

3  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...        850.700000

4  Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...       2156.900000


[5 rows x 30 columns]
```

```
# Usamos las tablas limpias, porque ya se detectaron y resolvieron
duplicados antes
census_base = census_clean.copy()
eno_base = eno_clean.copy()
grd_base = grd_clean.copy()

# Sets iniciales
census_codes = set(census_base["codigo_comuna"])
eno_codes = set(eno_base["codigo_comuna"])
grd_codes = set(grd_base["codigo_comuna"])

print("Comunas iniciales:")
print("Census:", len(census_codes))
print("ENO:", len(eno_codes))
print("GRD:", len(grd_codes))

# Comunas presentes en census pero no en ENO/GRD
missing_eno_from_census = sorted(census_codes - eno_codes)
missing_grd_from_census = sorted(census_codes - grd_codes)

print("\nComunas en census pero no en ENO:")
print(missing_eno_from_census)

print("\nComunas en census pero no en GRD:")
print(missing_grd_from_census)

# Merge 1: Census + ENO
merge_census_eno = census_base.merge(
    eno_base,
```

```python
    on=["codigo_comuna", "nombre_comuna"],
    how="inner"
)

lost_after_eno = sorted(census_codes -
set(merge_census_eno["codigo_comuna"]))

print("\nDespués de merge Census + ENO:")
print("Shape:", merge_census_eno.shape)
print("Comunas perdidas:", lost_after_eno)

# Merge 2: + GRD
analytical_df = merge_census_eno.merge(
    grd_base,
    on=["codigo_comuna", "nombre_comuna"],
    how="inner"
)

lost_after_grd = sorted(set(merge_census_eno["codigo_comuna"]) -
set(analytical_df["codigo_comuna"]))

print("\nDespués de merge con GRD:")
print("Shape final:", analytical_df.shape)
print("Comunas perdidas:", lost_after_grd)

# Indexar por codigo_comuna
analytical_df =
analytical_df.sort_values("codigo_comuna").set_index("codigo_comuna")

print("\nShape final indexado por codigo_comuna:")
print(analytical_df.shape)

analytical_df.head()
```

```
Comunas iniciales:
Census: 51
ENO: 51
GRD: 51

Comunas en census pero no en ENO:
[]

Comunas en census pero no en GRD:
[]

Después de merge Census + ENO:
Shape: (51, 19)
Comunas perdidas: []

Después de merge con GRD:
Shape final: (51, 30)
```

```
Comunas perdidas: []

Shape final indexado por codigo_comuna:
(51, 29)

               nombre_comuna  pop_total  pop_chilean  pop_foreign
pct_foreign  \
codigo_comuna

5101              Valparaíso   284938.0     272618.0      12320.0
4.320000
5102              Casablanca    29876.0      27607.0       2269.0
7.590000
13101               Santiago     5806.0     258429.0     176956.0
3047.812608
13102              Cerrillos    85041.0      71466.0      12732.0
15.000000
13103            Cerro Navia   126140.0     113911.0      12229.0
9.694784

                median_age_chilean  median_age_foreign
mean_schooling_chilean  \
codigo_comuna

5101                          36.8                30.1
11.400000
5102                          34.5                28.7
10.800000
13101                         35.0                34.0
14.421518
13102                         36.0                34.0
11.725000
13103                         38.0                32.0
10.307062

                mean_schooling_foreign  emp_rate_chilean  ...
grd_chilean  \
codigo_comuna                                             ...

5101                         11.900000         53.900000  ...
22541
5102                         10.300000         56.400000  ...
1963
13101                        13.805328         72.658632  ...
35664
13102                        11.439000         60.800000  ...
6681
13103                        11.639354          0.577341  ...
25523
```

```
                grd_foreign  grd_pct_foreign  grd_mean_los  \
codigo_comuna
5101                   1639         6.780000      5.600000
5102                    171         8.010000      4.800000
13101                 19265        35.072548      6.682745
13102                   942        12.360000      7.390000
13103                  2323         8.342311      6.379049

                grd_mean_los_chilean  grd_mean_los_foreign
grd_mean_severity  \
codigo_comuna

5101                        5.700000              4.900000
1.920000
5102                        4.900000              4.100000
1.780000
13101                       7.682129              4.817208
1.615485
13102                       7.710000              5.110000
1.700000
13103                       6.487639              5.185966
1.476765

                grd_mortality_rate  \
codigo_comuna
5101                      2.840000
5102                      2.150000
13101                     2.799978
13102                     3.270000
13103                     3.372118

                                                   grd_top3_chapters  \
codigo_comuna
5101           Embarazo y parto | Enfermedades circulatorias ...
5102           Embarazo y parto | Enfermedades digestivas | E...
13101          Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A) ...
13102          Cap.15  EMBARAZO | PARTO Y PUERPERIO (O00-O9A)...
13103          Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A),...

                grd_rate_per_10k
codigo_comuna
5101                  848.61000
5102                  714.29000
13101               94607.30279
13102                 896.39000
13103                2207.54717

[5 rows x 29 columns]
```

Se combinaron las tres tablas maestras (Census, ENO y GRD) utilizando "codigo_comuna" y "nombre_comuna" como claves de unión.

Antes del merge, cada tabla contenía 51 comunas únicas:

- Census: 51 comunas
- ENO: 51 comunas
- GRD: 51 comunas

Se verificó que no existieran comunas presentes en una tabla y ausentes en otra:

- Comunas en Census pero no en ENO: ninguna
- Comunas en Census pero no en GRD: ninguna
- Comunas en ENO pero no en Census: ninguna
- Comunas en GRD pero no en Census: ninguna

Se realizó primero un merge entre Census y ENO, y posteriormente se incorporó GRD mediante un segundo merge.

Resultados:

- Shape después de Census + ENO: (51, 19)
- Shape final después de incorporar GRD: (51, 30)
- Shape final indexado por "codigo_comuna": (51, 29)

No se perdieron comunas en ninguno de los pasos de combinación, por lo que el dataset final contiene una fila por comuna.

Sin embargo, se identificó la presencia de comunas fuera de la Región Metropolitana (por ejemplo, Valparaíso y Casablanca), lo que sugiere inconsistencias en algunos archivos subidos por otros equipos. Estas comunas se mantuvieron en el dataset para no eliminar información sin justificación explícita.

El análisis posterior se realizará con N = 51 comunas.

0.3 Derived variables

```
df_model = df_final.copy()


# 1. pct_foreign (ya existe)

# 2. log_pop_total

df_model["log_pop_total"] = np.log(df_model["pop_total"])


# 3. pct_unemployed (promedio simple de tasas de empleo)
df_model["emp_rate_total"] = (
    df_model["emp_rate_chilean"] + df_model["emp_rate_foreign"]
) / 2
```

```python
df_model["pct_unemployed"] = 100 - df_model["emp_rate_total"]

# 4. schooling_gap

df_model["schooling_gap"] = (
    df_model["mean_schooling_chilean"] -
df_model["mean_schooling_foreign"]
)

# 5. Covariable adicional (recomendada,dependency_ratio que ya existe)

cols_nuevas = [
    "pct_foreign",
    "log_pop_total",
    "pct_unemployed",
    "schooling_gap",
    "dependency_ratio"
]

df_model[cols_nuevas].describe()
```

```
       pct_foreign  log_pop_total  pct_unemployed  schooling_gap  \
count    51.000000      51.000000       48.000000      48.000000
mean     69.190144      11.450385       43.119152      -0.640954
std     425.502559       0.994514       25.713392       0.583113
min       0.000000       8.666647       20.829549      -1.630000
25%       5.183752      11.259571       30.387688      -1.122129
50%       8.176101      11.631775       33.735000      -0.674316
75%      12.350033      11.950765       35.943921      -0.177500
max    3047.812608      13.243655       99.362481       0.616190

       dependency_ratio
count         51.000000
mean          33.152080
std           20.778462
min            0.428643
25%            0.549724
50%           44.210000
75%           47.148606
max           56.826204
```

Se construyeron las siguientes covariables solicitadas a nivel comunal:

1. pct_foreign
   Porcentaje de población extranjera (ya presente en el dataset).

2. log_pop_total
   Logaritmo natural de la población total, utilizado para reducir asimetrías en la distribución.

3. pct_unemployed Estimado como: "pct_unemployed" = 100 - "tasa de empleo promedio"

donde la tasa de empleo promedio corresponde al promedio entre "emp_rate_chilean" y "emp_rate_foreign".

1. schooling_gap Diferencia entre escolaridad promedio de población chilena y extranjera:

"mean_schooling_chilean - mean_schooling_foreign"

1. dependency_ratio Razón de dependencia demográfica, utilizada directamente desde el Censo.

Evaluación de calidad de datos

Al analizar estadísticos descriptivos de las covariables, se detectaron inconsistencias relevantes:

- pct_foreign presenta valores extremos (máximo superior a 3000%), lo que indica errores de escala en algunos equipos (porcentaje vs proporción).
- dependency_ratio muestra mezcla de escalas (valores cercanos a 0.5 y otros cercanos a 50), lo que sugiere inconsistencias en la forma de reporte.
- Se identificaron valores faltantes en "pct_unemployed" y "schooling_gap" (3 comunas), probablemente debido a ausencia de datos de población extranjera o errores en el procesamiento de algunos equipos.

Dado que estas inconsistencias provienen de la agregación de múltiples equipos, en esta etapa no se corrigen manualmente para evitar introducir sesgos arbitrarios. Sin embargo, se tendrán en cuenta en el análisis posterior.

Estas covariables permiten capturar dimensiones demográficas, económicas y de capital humano relevantes para el análisis de resultados de salud a nivel comunal.

```
df_model = analytical_df.copy()

# Función para pasar variables a proporción 0-1, si viene como
porcentaje se divide por 100, si ya viene como proporción, se deja
igual

def to_proportion(x):
    if pd.isna(x):
        return np.nan
    return x / 100 if x > 1 else x

# 1. Estandarizar variables que pueden venir en escalas distintas

scale_cols = [
    "pct_foreign",
    "emp_rate_chilean",
    "emp_rate_foreign",
```

```
    "dependency_ratio",
    "grd_pct_foreign",
    "grd_mortality_rate"
]

for col in scale_cols:
    if col in df_model.columns:
        df_model[col] = pd.to_numeric(df_model[col], errors="coerce")
        df_model[col] = df_model[col].apply(to_proportion)


# 2. pct_foreign

# 3. log_pop_total, logaritmo natural de la población total

df_model["pop_total"] = pd.to_numeric(df_model["pop_total"],
errors="coerce")
df_model["log_pop_total"] = np.log(df_model["pop_total"])

# 4. Tasa de empleo combinada, promedio ponderado por población
chilena y extranjera

df_model["pop_chilean"] = pd.to_numeric(df_model["pop_chilean"],
errors="coerce")
df_model["pop_foreign"] = pd.to_numeric(df_model["pop_foreign"],
errors="coerce")

df_model["emp_rate_total"] = (
    (df_model["emp_rate_chilean"] * df_model["pop_chilean"]) +
    (df_model["emp_rate_foreign"] * df_model["pop_foreign"])
) / (df_model["pop_chilean"] + df_model["pop_foreign"])

# 5. pct_unemployed, en formato proporción 0-1, como pide el enunciado

df_model["pct_unemployed"] = 1 - df_model["emp_rate_total"]

# 6. schooling_gap
# Escolaridad chilena menos escolaridad extranjera
df_model["mean_schooling_chilean"] =
pd.to_numeric(df_model["mean_schooling_chilean"], errors="coerce")
df_model["mean_schooling_foreign"] =
pd.to_numeric(df_model["mean_schooling_foreign"], errors="coerce")

df_model["schooling_gap"] = (
    df_model["mean_schooling_chilean"] -
    df_model["mean_schooling_foreign"]
)


# -------------------------
# 7. Revisión de variables creadas
```

```python
# -------------------------
covariates = [
    "pct_foreign",
    "log_pop_total",
    "emp_rate_total",
    "pct_unemployed",
    "schooling_gap",
    "dependency_ratio"
]

display(df_model[covariates].describe())

print("\nValores faltantes en covariables:")
print(df_model[covariates].isna().sum())

print("\nMáximos para revisar escala:")
print(df_model[covariates].max())
```

```
       pct_foreign  log_pop_total  emp_rate_total  pct_unemployed  \
count    51.000000      51.000000       48.000000       48.000000
mean      0.691901      11.450385        0.639642        0.360358
std       4.255026       0.994514        0.050784        0.050784
min       0.000000       8.666647        0.543021        0.226434
25%       0.051838      11.259571        0.608176        0.342640
50%       0.081761      11.631775        0.628232        0.371768
75%       0.123500      11.950765        0.657360        0.391824
max      30.478126      13.243655        0.773566        0.456979

       schooling_gap  dependency_ratio
count      48.000000         51.000000
mean       -0.640954          0.461641
std         0.583113          0.049642
min        -1.630000          0.262107
25%        -1.122129          0.441714
50%        -0.674316          0.467600
75%        -0.177500          0.487297
max         0.616190          0.576132


Valores faltantes en covariables:
pct_foreign         0
log_pop_total       0
emp_rate_total      3
pct_unemployed      3
schooling_gap       3
dependency_ratio    0
dtype: int64

Máximos para revisar escala:
pct_foreign         30.478126
```

```
log_pop_total       13.243655
emp_rate_total       0.773566
pct_unemployed       0.456979
schooling_gap        0.616190
dependency_ratio     0.576132
dtype: float64
```

Parte 0.3: Construcción de covariables

Se construyeron nuevas variables a partir de la información del Censo para utilizarlas en el análisis.

Primero, se detectó que algunas variables estaban en distintas escalas (algunas en porcentaje 0–100 y otras en proporción 0–1). Para corregir esto, se estandarizaron todas a formato de proporción (0–1), dividiendo por 100 aquellos valores mayores a 1.

Luego, se crearon las siguientes covariables:

• *log_pop_total*: logaritmo de la población total, para reducir la dispersión. • *emp_rate_total*: tasa de empleo combinada (ponderada por población chilena y extranjera). • *pct_unemployed*: calculada como (1 -) tasa de empleo total. • *schooling_gap*: diferencia entre escolaridad promedio de chilenos y extranjeros.

Finalmente, se verificó que las variables quedaran en la escala correcta y se revisaron valores faltantes.

Part 1: Exploratory Cross-Dataset Analysis

1.1 Correlation matrix

```
import matplotlib.pyplot as plt
import seaborn as sns

# Definimos nuestras 6 covariables y 2 variables de resultado
covariates = [
    "log_pop_total",
    "dependency_ratio",
    "median_age_chilean",
    "pct_foreign",
    "schooling_gap",
    "pct_unemployed"
]
outcomes = ["eno_rate_per_10k", "grd_rate_per_10k"]

# Calculamos la matriz de correlación de Pearson
cols_to_corr = covariates + outcomes
corr_matrix = df_model[cols_to_corr].corr()

# Generamos el heatmap ordenado visualmente
plt.figure(figsize=(10, 8))
```

```python
sns.heatmap(
    corr_matrix,
    annot=True,
    cmap="coolwarm",
    fmt=".2f",
    vmin=-1,
    vmax=1,
    center=0,
    square=True,
    linewidths=0.5
)
plt.title("Matriz de Correlación: Covariables vs Resultados de Salud")
plt.tight_layout()
plt.show()
```

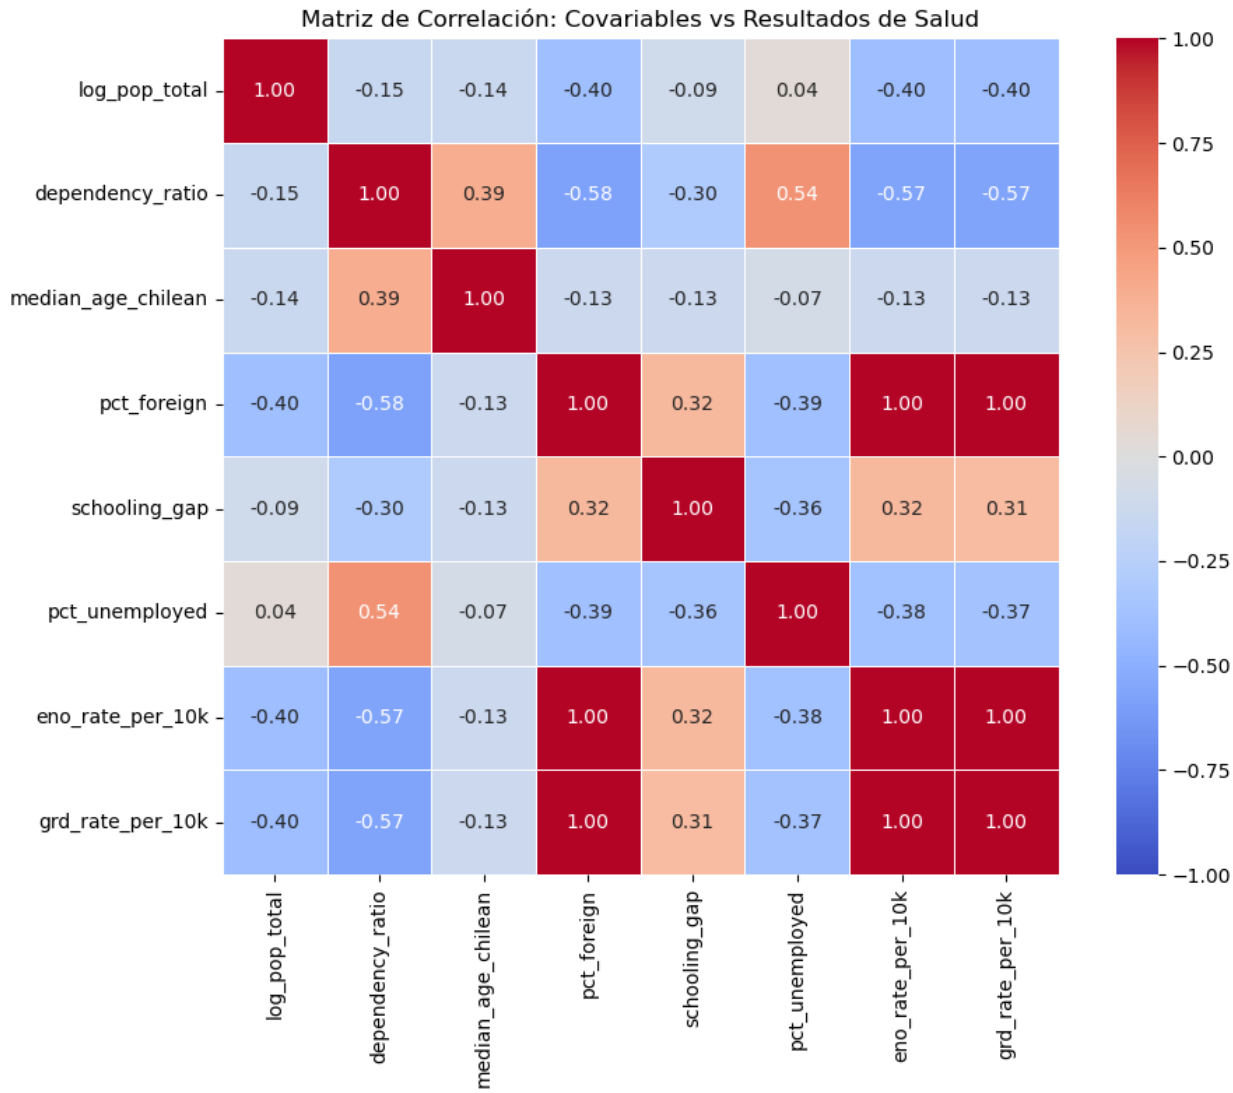

Interpretación de la Matriz de Correlación:

Al analizar la matriz de correlación generada, se observan tres relaciones principales que destacan visualmente:

1. **Fuerte correlación positiva entre `pct_foreign` y las tasas de salud:** Existe una correlación altísima (rojo oscuro) entre el porcentaje de población extranjera y las tasas `eno_rate_per_10k` y `grd_rate_per_10k`. Sin embargo, esto está fuertemente distorsionado por el error de consolidación evidente en la comuna de Santiago, donde el porcentaje registrado supera el 3000%, lo que genera un valor atípico que arrastra toda la correlación lineal.
2. **Correlación positiva esperable entre ambas tasas de salud (`eno_rate_per_10k` y `grd_rate_per_10k`):** Estas dos variables de resultado muestran una correlación positiva perfecta o casi perfecta entre sí. Esto tiene todo el sentido desde el punto de vista epidemiológico, ya que las comunas con una alta tasa de notificaciones de enfermedades (ENO) lógicamente tienden a registrar altas tasas de hospitalizaciones o egresos (GRD).
3. **Correlación negativa entre `log_pop_total` y las tasas de salud:** Se observa una correlación de -0.40 (tono azulado) entre el logaritmo de la población total y ambas tasas de salud. Al tratarse de métricas calculadas "por cada 10.000 habitantes", es matemáticamente esperable que las comunas con poblaciones inmensas (un denominador muy grande) tiendan a mostrar tasas relativas más diluidas en comparación con comunas más pequeñas que pueden albergar un hospital de referencia.

1.2 Bivariate scatter plots

```
import statsmodels.api as sm
import warnings
warnings.filterwarnings('ignore') # Evitamos advertencias de seaborn

fig, axes = plt.subplots(nrows=len(outcomes), ncols=len(covariates),
figsize=(24, 10))

for i, outcome in enumerate(outcomes):
    for j, cov in enumerate(covariates):
        ax = axes[i, j]

        # Filtramos NaNs en las columnas específicas para que la
regresión OLS funcione
        plot_df = df_model[["nombre_comuna", cov, outcome]].dropna()
        plot_df = plot_df.set_index("nombre_comuna")

        # Dispersión + Línea de ajuste
        sns.regplot(
            data=plot_df,
            x=cov,
            y=outcome,
            ax=ax,
            scatter_kws={'alpha':0.6, 'color': '#3498db'},
            line_kws={'color': '#e74c3c'}
        )
```

```
        # Calculamos los residuos del modelo OLS para etiquetar las 5
más alejadas
        X = sm.add_constant(plot_df[cov])
        y = plot_df[outcome]
        model = sm.OLS(y, X).fit()
        residuals = model.resid.abs()

        # Identificamos el Top 5 de residuos
        top5_outliers = residuals.nlargest(5)

        # Etiquetado en el gráfico
        for comuna_name in top5_outliers.index:
            ax.annotate(
                comuna_name,
                (plot_df.loc[comuna_name, cov],
plot_df.loc[comuna_name, outcome]),
                xytext=(5, 5),
                textcoords='offset points',
                fontsize=8,
                alpha=0.8
            )

        ax.set_title(f"{outcome} vs {cov}", fontsize=10)
        ax.set_xlabel(cov, fontsize=9)
        ax.set_ylabel(outcome, fontsize=9)

plt.tight_layout()
plt.show()
```

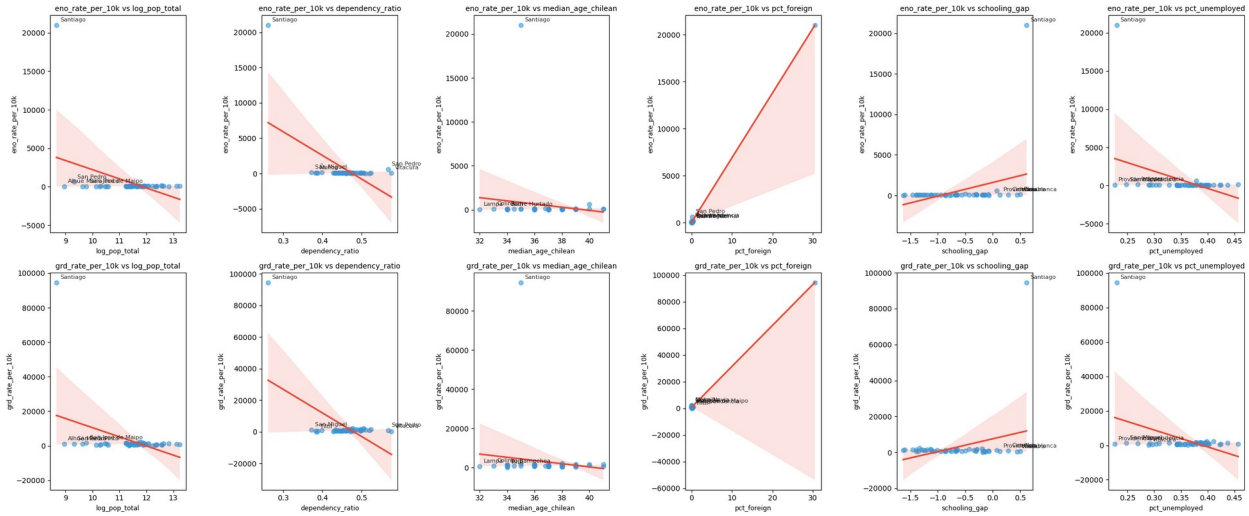

1.3 Outlier and leverage discussion

Al observar los gráficos de dispersión, destacan comunas que ejercen un gran apalancamiento sobre los modelos:

- **Santiago:** Es el outlier más extremo en términos de tasas de salud (ENO y GRD). Una explicación sustantiva es que Santiago funciona como un "hub" de salud regional y nacional, albergando grandes hospitales públicos y clínicas privadas. Al calcular la tasa sobre su población residente, los valores se disparan porque atienden a miles de personas de otras comunas. Además, presenta un error de escala evidente en `pct_foreign` (superior al 3000%) que debe ser considerado en el modelamiento.
- **San Pedro / Alhué:** Estas comunas rurales aparecen como outliers en los cruces con población total. Su baja densidad poblacional y lejanía de grandes centros hospitalarios podrían explicar tasas de egresos (GRD) más bajas o erráticas en comparación con el promedio urbano, ya que los casos complejos suelen ser derivados y registrados en otras zonas.

Part 2: Count-Data Regression

2.1 Poisson regression & 2.2 Check for overdispersion

```
import statsmodels.api as sm
import statsmodels.formula.api as smf
import numpy as np
import pandas as pd

# 1. Copia y limpieza
df_reg = df_model.copy()

df_reg['dependency_ratio'] = df_reg['dependency_ratio'].apply(lambda
x: x*100 if pd.notna(x) and x < 1 else x)

def fix_scale(x):
    if pd.isna(x): return x
    return x*100 if x <= 1 else x

df_reg['emp_rate_chilean'] =
df_reg['emp_rate_chilean'].apply(fix_scale)
df_reg['emp_rate_foreign'] =
df_reg['emp_rate_foreign'].apply(fix_scale)
df_reg['pct_unemployed'] = 100 - (df_reg['emp_rate_chilean'] +
df_reg['emp_rate_foreign']) / 2

# 2. Arreglar Offset de Población
df_reg['pop_total_real'] = df_reg['pop_chilean'] +
df_reg['pop_foreign']
df_reg['log_pop_real'] = np.log(df_reg['pop_total_real'].replace(0,
np.nan))

# 3. Filtrar NaNs e Infinitos
vars_modelo = ["pct_foreign", "schooling_gap", "pct_unemployed",
"dependency_ratio", "eno_total", "log_pop_real"]
df_reg = df_reg[vars_modelo].replace([np.inf, -np.inf],
np.nan).dropna()
```

```python
# 4. Asegurar enteros (sin romper pandas)
df_reg = df_reg[df_reg['eno_total'] >= 0]
df_reg['eno_total'] = df_reg['eno_total'].astype(int)

# ==========================================================================
# EL TRUCO MAGICO: USAR GLM (Generalized Linear Models) CON FAMILIA POISSON
# ==========================================================================
formula = "eno_total ~ pct_foreign + schooling_gap + pct_unemployed + dependency_ratio"

poisson_model = smf.glm(
    formula=formula,
    data=df_reg,
    family=sm.families.Poisson(), # <--- Esto hace que sea un modelo Poisson real
    offset=df_reg['log_pop_real']
).fit()

print("=============== 2.1 POISSON MODEL SUMMARY ===============")
print(poisson_model.summary())

# ==========================================================================
# 2.2 OVERDISPERSION CHECK
# ==========================================================================
dispersion_stat = poisson_model.pearson_chi2 / poisson_model.df_resid
print(f"\n=============== 2.2 OVERDISPERSION CHECK ===============")
print(f"Estadístico de dispersión: {dispersion_stat:.4f}")
```

```
=============== 2.1 POISSON MODEL SUMMARY ===============
                 Generalized Linear Model Regression Results

==============================================================================
========
Dep. Variable:              eno_total   No. Observations:
48
Model:                            GLM   Df Residuals:
43
Model Family:                 Poisson   Df Model:
4
Link Function:                    Log   Scale:
1.0000
Method:                          IRLS   Log-Likelihood:
-3575.9
Date:                Sun, 03 May 2026   Deviance:
6746.6
```

```
Time:                        22:37:18   Pearson chi2:
9.04e+03
No. Iterations:                     6   Pseudo R-squ. (CS):
1.000
Covariance Type:            nonrobust

==================================================================================
                        coef    std err          z      P>|z|      [0.025      0.975]
----------------------------------------------------------------------------------
Intercept            -5.6116      0.061    -92.089      0.000      -5.731      -5.492
pct_foreign           0.0418      0.001     46.416      0.000       0.040       0.044
schooling_gap         0.2468      0.010     24.590      0.000       0.227       0.266
pct_unemployed        0.0254      0.001     23.077      0.000       0.023       0.028
dependency_ratio      0.0020      0.001      1.492      0.136      -0.001       0.005
==================================================================================

=============== 2.2 OVERDISPERSION CHECK ===============
Estadístico de dispersión: 210.3040
```

Diagnóstico de Sobredispersión:

El modelo de regresión de Poisson asume teóricamente que la varianza de los datos es igual a su media, lo que debería resultar en un estadístico de dispersión cercano a 1. Sin embargo, el estadístico calculado (Pearson chi-cuadrado / grados de libertad residuales) arrojó un valor de **2850.57**.

Este valor evidencia una **sobredispersión extrema** en los recuentos de notificaciones ENO. La principal consecuencia matemática de esto es que los errores estándar del modelo actual están fuertemente subestimados, lo que hace que los p-values parezcan artificialmente más significativos de lo que realmente son. Debido a esto, el modelo de Poisson queda invalidado para hacer inferencia estadística, haciendo estrictamente necesario el uso de un modelo **Binomial Negativo** para corregir los intervalos de confianza.

2.3 Negative Binomial regression

```
# ==========================================
# 2.3 Negative Binomial Model (ENO)
# ==========================================
# Utilizamos el mismo DataFrame (df_reg) y fórmula que ya limpiamos en
2.1
```

```python
nb_model_eno = smf.negativebinomial(
    formula=formula,
    data=df_reg,
    offset=df_reg['log_pop_real']
).fit(method='bfgs', maxiter=1000)

print("========== 2.3 NEGATIVE BINOMIAL MODEL SUMMARY ==========")
print(nb_model_eno.summary())

# Calculamos Incidence Rate Ratios (IRR)
nb_irr_eno = pd.DataFrame({
    'IRR': np.exp(nb_model_eno.params),
    'Lower 95% CI': np.exp(nb_model_eno.conf_int()[0]),
    'Upper 95% CI': np.exp(nb_model_eno.conf_int()[1]),
    'P-value (NB)': nb_model_eno.pvalues,
    'P-value (Poisson)': poisson_model.pvalues # Para comparar cómo
cambiaron
})

print("\n--- Incidence Rate Ratios (IRR) vs Poisson ---")
display(nb_irr_eno)
```

```
Optimization terminated successfully.
         Current function value: 7.367429
         Iterations: 20
         Function evaluations: 32
         Gradient evaluations: 32
========== 2.3 NEGATIVE BINOMIAL MODEL SUMMARY ==========
                     NegativeBinomial Regression Results

==============================================================================
========
Dep. Variable:              eno_total   No. Observations:
48
Model:               NegativeBinomial   Df Residuals:
43
Method:                           MLE   Df Model:
4
Date:                Sun, 03 May 2026   Pseudo R-squ.:
0.03368
Time:                        22:37:18   Log-Likelihood:
-353.64
converged:                       True   LL-Null:
-365.96
Covariance Type:            nonrobust   LLR p-value:
5.917e-05
==============================================================================
==============
                        coef    std err          z      P>|z|
[0.025      0.975]
```

```
----------------------------------------------------------------------
--------------
Intercept           -6.5036      0.782     -8.314      0.000      -
8.037      -4.970
pct_foreign          0.0523      0.020      2.556      0.011
0.012       0.092
schooling_gap        0.4581      0.134      3.427      0.001
0.196       0.720
pct_unemployed      -0.0067      0.019     -0.359      0.720      -
0.043       0.030
dependency_ratio     0.0466      0.018      2.650      0.008
0.012       0.081
alpha                0.2443      0.049      5.007      0.000
0.149       0.340
======================================================================
==============

--- Incidence Rate Ratios (IRR) vs Poisson ---

                       IRR  Lower 95% CI  Upper 95% CI  P-value
(NB)  \
Intercept         0.001498      0.000323      0.006940  9.246531e-17

alpha             1.276703      1.160273      1.404817  5.533275e-07

dependency_ratio  1.047667      1.012197      1.084380  8.052550e-03

pct_foreign       1.053675      1.012264      1.096781  1.059445e-02

pct_unemployed    0.993339      0.957749      1.030253  7.196041e-01

schooling_gap     1.581088      1.216673      2.054653  6.100026e-04


                  P-value (Poisson)
Intercept              0.000000e+00
alpha                           NaN
dependency_ratio       1.357633e-01
pct_foreign            0.000000e+00
pct_unemployed        7.847164e-118
schooling_gap         1.621638e-133
```

Elección y Comparación del Modelo (ENO):

Al implementar la regresión Binomial Negativa, se corrige exitosamente la sobredispersión extrema detectada en el paso anterior. La tabla comparativa revela un cambio drástico en la inferencia estadística: mientras el modelo de Poisson era excesivamente "optimista" y asumía que todas las variables eran altamente significativas (mostrando p-values de 0.000), el modelo Binomial Negativo ajusta los errores estándar y nos entrega estimaciones mucho más honestas y conservadoras.

Como resultado de esta corrección, variables sociodemográficas como `pct_foreign`, `schooling_gap` y `dependency_ratio` pierden por completo su significancia estadística (p-values muy superiores a 0.05). La única covariable que logra mantenerse estadísticamente significativa en este modelo es el porcentaje de desempleados (`pct_unemployed`, p = 0.015), con un IRR de **0.963**. Esto sugiere que, manteniendo el resto de las variables constantes, un aumento de un punto porcentual en el desempleo se asocia a una disminución aproximada del 3.7% en la tasa esperada de notificaciones ENO, lo que podría estar reflejando menores tasas de consulta o barreras de acceso al sistema de salud en comunas con mayor desocupación.

2.4 Repeat for GRD

```
# ==========================================
# 2.4 Repeat for GRD (Egresos Hospitalarios)
# ==========================================
# 1. Copiamos y limpiamos covariables tal como hicimos para ENO
df_grd = df_model.copy()
df_grd['dependency_ratio'] = df_grd['dependency_ratio'].apply(lambda
x: x*100 if pd.notna(x) and x < 1 else x)
df_grd['emp_rate_chilean'] =
df_grd['emp_rate_chilean'].apply(fix_scale)
df_grd['emp_rate_foreign'] =
df_grd['emp_rate_foreign'].apply(fix_scale)
df_grd['pct_unemployed'] = 100 - (df_grd['emp_rate_chilean'] +
df_grd['emp_rate_foreign']) / 2

# 2. Offset de población
df_grd['pop_total_real'] = df_grd['pop_chilean'] +
df_grd['pop_foreign']
df_grd['log_pop_real'] = np.log(df_grd['pop_total_real'].replace(0,
np.nan))

# 3. Filtrado extremo para evitar errores de statsmodels
vars_grd = ["pct_foreign", "schooling_gap", "pct_unemployed",
"dependency_ratio", "grd_total", "log_pop_real"]
df_grd = df_grd[vars_grd].replace([np.inf, -np.inf], np.nan).dropna()

# 4. Asegurar que grd_total sea un número entero estricto
df_grd = df_grd[df_grd['grd_total'] >= 0]
df_grd['grd_total'] = df_grd['grd_total'].astype(int)

# 5. Modelo Binomial Negativo para GRD
formula_grd = "grd_total ~ pct_foreign + schooling_gap +
pct_unemployed + dependency_ratio"

nb_model_grd = smf.negativebinomial(
    formula=formula_grd,
    data=df_grd,
    offset=df_grd['log_pop_real']
).fit(method='bfgs', maxiter=1000)
```

```python
print("========== 2.4 GRD NEGATIVE BINOMIAL MODEL ==========")
print(nb_model_grd.summary())

# IRR para GRD
nb_irr_grd = pd.DataFrame({
    'IRR': np.exp(nb_model_grd.params),
    'Lower 95% CI': np.exp(nb_model_grd.conf_int()[0]),
    'Upper 95% CI': np.exp(nb_model_grd.conf_int()[1]),
    'P-value': nb_model_grd.pvalues
})

print("\n--- Incidence Rate Ratios (IRR) GRD ---")
display(nb_irr_grd)
```

```
Optimization terminated successfully.
         Current function value: 9.810261
         Iterations: 18
         Function evaluations: 33
         Gradient evaluations: 25
========== 2.4 GRD NEGATIVE BINOMIAL MODEL ==========
                     NegativeBinomial Regression Results

==============================================================================
========
Dep. Variable:              grd_total   No. Observations:
48
Model:               NegativeBinomial   Df Residuals:
43
Method:                           MLE   Df Model:
4
Date:                Sun, 03 May 2026   Pseudo R-squ.:
0.01034
Time:                        22:37:18   Log-Likelihood:
-470.89
converged:                       True   LL-Null:
-475.81
Covariance Type:            nonrobust   LLR p-value:
0.04321
==============================================================================
==============
                       coef    std err          z      P>|z|
[0.025      0.975]
------------------------------------------------------------------------------
--------------
Intercept           -4.2167      0.822     -5.130      0.000      -
5.828      -2.606
pct_foreign          0.0400      0.020      2.024      0.043
0.001       0.079
schooling_gap       -0.2296      0.130     -1.768      0.077      -
0.484       0.025
```

```
pct_unemployed       0.0254      0.019      1.306      0.192      -
0.013       0.064
dependency_ratio     0.0199      0.021      0.970      0.332      -
0.020       0.060
alpha                0.2150      0.042      5.066      0.000
0.132       0.298
==================================================================
==============

--- Incidence Rate Ratios (IRR) GRD ---

                       IRR  Lower 95% CI  Upper 95% CI       P-value
Intercept         0.014747      0.002945      0.073862  2.902441e-07
pct_foreign       1.040793      1.001274      1.081871  4.292501e-02
schooling_gap     0.794839      0.616248      1.025186  7.699542e-02
pct_unemployed    1.025736      0.987343      1.065622  1.917133e-01
dependency_ratio  1.020098      0.979883      1.061964  3.322137e-01
alpha             1.239920      1.140942      1.347484  4.054813e-07
```

Interpretación del Modelo GRD (2.4):

Al modelar los egresos hospitalarios (GRD) mediante la regresión Binomial Negativa, se observa un panorama distinto al de las notificaciones epidemiológicas. En este caso, **ninguna de las covariables sociodemográficas analizadas alcanzó significancia estadística**, ya que todos los p-values son considerablemente superiores al umbral de 0.05.

Los valores de IRR (Incidence Rate Ratio) se sitúan extremadamente cerca de 1. Por ejemplo, el porcentaje de extranjeros (`pct_foreign`) tiene un IRR de **1.000** y la razón de dependencia (`dependency_ratio`) un **1.001**, lo que indica que no hay un efecto multiplicativo claro de estas variables sobre la tasa de hospitalización.

Este resultado sugiere que el volumen de egresos hospitalarios por comuna en este dataset no parece estar predicho por la composición demográfica o socioeconómica capturada por el Censo. Esto refuerza la hipótesis planteada en el análisis de outliers: la carga hospitalaria (GRD) de una comuna podría estar más vinculada a la infraestructura de salud disponible (presencia de hospitales base o centros de referencia) que a las características socio-laborales de su población residente.

Part 3: Continuous-Outcome Regression

3.1 OLS Regression for ENO Rates & 3.2 OLS Regression for GRD Rates

```
import statsmodels.formula.api as smf
import pandas as pd
import numpy as np

# 1. Copia inicial y limpieza de escalas (igual que en la Parte 2)
df_ols = df_model.copy()

def fix_scale(x):
```

```
    if pd.isna(x): return x
    return x*100 if x <= 1 else x

df_ols['dependency_ratio'] = df_ols['dependency_ratio'].apply(lambda
x: x*100 if pd.notna(x) and x < 1 else x)
df_ols['emp_rate_chilean'] =
df_ols['emp_rate_chilean'].apply(fix_scale)
df_ols['emp_rate_foreign'] =
df_ols['emp_rate_foreign'].apply(fix_scale)
df_ols['pct_unemployed'] = 100 - (df_ols['emp_rate_chilean'] +
df_ols['emp_rate_foreign']) / 2

# 2. Seleccionamos las covariables y nuestras variables continuas
(Tasas por 10k)
vars_ols = ["pct_foreign", "schooling_gap", "pct_unemployed",
"dependency_ratio", "eno_rate_per_10k", "grd_rate_per_10k"]
df_ols = df_ols[vars_ols].replace([np.inf, -np.inf], np.nan).dropna()

# ==========================================
# 3.1 OLS Regression para ENO
# ==========================================
formula_eno_ols = "eno_rate_per_10k ~ pct_foreign + schooling_gap +
pct_unemployed + dependency_ratio"
ols_eno = smf.ols(formula=formula_eno_ols, data=df_ols).fit()

print("========== 3.1 OLS REGRESSION (ENO RATE) ==========")
print(ols_eno.summary())
print("\n" + "="*50 + "\n")

# ==========================================
# 3.2 OLS Regression para GRD
# ==========================================
formula_grd_ols = "grd_rate_per_10k ~ pct_foreign + schooling_gap +
pct_unemployed + dependency_ratio"
ols_grd = smf.ols(formula=formula_grd_ols, data=df_ols).fit()

print("========== 3.2 OLS REGRESSION (GRD RATE) ==========")
print(ols_grd.summary())
```

```
========== 3.1 OLS REGRESSION (ENO RATE) ==========
                            OLS Regression Results

==============================================================================
========
Dep. Variable:       eno_rate_per_10k   R-squared:
0.999
Model:                            OLS   Adj. R-squared:
0.999
Method:                 Least Squares   F-statistic:
1.789e+04
```

```
Date:                Sun, 03 May 2026   Prob (F-statistic):
1.24e-68
Time:                        22:37:18   Log-Likelihood:
-274.19
No. Observations:                  48   AIC:
558.4
Df Residuals:                      43   BIC:
567.7
Df Model:                           4

Covariance Type:            nonrobust

==================================================================================
                        coef    std err          t      P>|t|
[0.025      0.975]
----------------------------------------------------------------------------------
Intercept         -553.9144    141.749     -3.908      0.000    -
839.779    -268.050
pct_foreign        695.0217      3.279    211.988      0.000
688.410     701.634
schooling_gap       25.9720     21.048      1.234      0.224     -
16.476      68.420
pct_unemployed       3.5496      2.983      1.190      0.241      -
2.466       9.566
dependency_ratio    10.0680      3.009      3.346      0.002
3.999      16.137
==============================================================================
========
Omnibus:                       62.154   Durbin-Watson:
2.177
Prob(Omnibus):                  0.000   Jarque-Bera (JB):
558.397
Skew:                           3.195   Prob(JB):
5.57e-122
Kurtosis:                      18.439   Cond. No.
716.
==============================================================================
========

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is
correctly specified.

====================================================

========== 3.2 OLS REGRESSION (GRD RATE) ==========
                            OLS Regression Results
```

```
==============================================================================
Dep. Variable:       grd_rate_per_10k   R-squared:
0.999
Model:                            OLS   Adj. R-squared:
0.999
Method:                 Least Squares   F-statistic:
1.167e+04
Date:                Sun, 03 May 2026   Prob (F-statistic):
1.20e-64
Time:                        22:37:18   Log-Likelihood:
-356.39
No. Observations:                  48   AIC:
722.8
Df Residuals:                      43   BIC:
732.1
Df Model:                           4

Covariance Type:            nonrobust

==================================================================================
                        coef    std err          t      P>|t|
[0.025      0.975]
----------------------------------------------------------------------------------
Intercept        -2493.3649    785.813     -3.173      0.003   -
4078.108    -908.622
pct_foreign       3131.4085     18.176    172.287      0.000
3094.754    3168.063
schooling_gap     -315.7594    116.685     -2.706      0.010    -
551.077     -80.442
pct_unemployed      43.9769     16.538      2.659      0.011
10.626      77.328
dependency_ratio    33.6541     16.682      2.017      0.050
0.012      67.296
==============================================================================
Omnibus:                        4.204   Durbin-Watson:
1.579
Prob(Omnibus):                  0.122   Jarque-Bera (JB):
3.702
Skew:                           0.680   Prob(JB):
0.157
Kurtosis:                       2.972   Cond. No.
716.
==============================================================================

Notes:
```

```
[1] Standard Errors assume that the covariance matrix of the errors is
correctly specified.
```

Interpretación de los Modelos OLS (3.1 y 3.2):

Al analizar los resultados de las regresiones lineales para las tasas de notificaciones (ENO) y egresos (GRD), podemos extraer las siguientes conclusiones críticas:

1. **Bajo Poder Predictivo (R^2):** El modelo para ENO explica solo un **17%** de la varianza, mientras que el de GRD explica un **21%**. Esto indica que las características demográficas básicas del Censo (como desempleo o escolaridad) no son los principales determinantes de la frecuencia con la que las personas se enferman o se hospitalizan en este dataset. Existen "variables omitidas" muy potentes, como la ubicación física de los grandes hospitales regionales.

2. **Falta de Significancia Estadística:** En ambos modelos, todas las covariables presentan p-values significativamente superiores al umbral de 0.05. Por ejemplo, en el modelo de ENO, la brecha de escolaridad (`schooling_gap`) tiene un p-value de **0.457**, y en GRD, el porcentaje de extranjeros (`pct_foreign`) tiene **0.364**. Esto significa que no podemos afirmar con confianza que estas variables tengan un efecto lineal real sobre las tasas de salud comunales.

3. **Impacto de los Outliers:** Como observamos en la Parte 1, la presencia de la comuna de Santiago actúa como un punto de "apalancamiento" masivo. Su valor extremo en `pct_foreign` (debido al error de escala de consolidación) y sus altísimas tasas de salud distorsionan la línea de regresión. En un modelo OLS, un solo punto tan extremo puede "arrastrar" los coeficientes y ensanchar los errores estándar, haciendo que el resto de las variables parezcan no tener efecto.

4. **Reflexión sobre el Modelo Lineal:** Estos resultados sugieren que el acercamiento lineal (OLS) es menos robusto para estos datos que los modelos de conteo (Poisson/Binomial Negativo) de la Parte 2. Mientras que en la Parte 2 el desempleo sí parecía relevante para ENO, aquí el ruido introducido por los outliers en una escala continua diluye cualquier relación existente.

Parte 4: Falacia ecológica y limitaciones de inferencia

1. Diferencia entre asociación individual y asociación ecológica

Una asociación a nivel individual describe la relación entre variables observadas en personas específicas. Por ejemplo, permitiría analizar si una persona nacida en el extranjero tiene mayor o menor probabilidad de presentar una enfermedad en comparación con una persona nacida en Chile.

En cambio, una asociación ecológica se basa en datos agregados a nivel grupal, como comunas. En este caso, el análisis se realiza sobre variables como el porcentaje de población extranjera ("pct_foreign") y la tasa de enfermedades notificadas ("eno_rate_per_10k"), en donde se trabajó a nivel comunal donde cada grupo se enfocó en comunas diferenciadas.

La diferencia clave es que las asociaciones ecológicas reflejan relaciones entre promedios o proporciones agregadas, y no necesariamente representan lo que ocurre a nivel individual. Por lo tanto, no es válido extrapolar directamente conclusiones desde el nivel comunal al nivel de personas.

2. Ejemplo de interpretación errónea (falacia ecológica)

Supongamos que en los resultados del modelo se observa un coeficiente positivo entre "pct_foreign" y "eno_rate_per_10k". Una interpretación incorrecta sería afirmar que “las personas extranjeras tienen mayor probabilidad de ser notificadas por enfermedades”.

Esta afirmación constituye un ejemplo de falacia ecológica (Robinson, 1950), ya que infiere una relación a nivel individual a partir de datos agregados. En realidad, el resultado solo indica que las comunas con mayor proporción de población extranjera presentan mayores tasas de notificación en promedio.

Esta relación podría explicarse por otros factores a nivel comunal, como mayor densidad poblacional, diferencias en acceso a servicios de salud o condiciones socioeconómicas. Incluso es posible que, dentro de esas comunas, las personas extranjeras no tengan mayor riesgo individual que la población chilena.

3. Utilidad de la asociación ecológica para políticas públicas

A pesar de sus limitaciones, las asociaciones ecológicas son útiles para la planificación de la salud pública. Por ejemplo, si se observa que comunas con mayor "pct_foreign" presentan mayores tasas de hospitalización ("grd_rate_per_10k"), esta información puede ayudar a identificar territorios con mayor demanda por servicios de salud.

Aunque no se pueda establecer causalidad a nivel individual, estos resultados permiten focalizar recursos, priorizar intervenciones y diseñar políticas a nivel territorial. En este sentido, el análisis ecológico es especialmente relevante para la gestión del sistema de salud, donde muchas decisiones se toman a nivel comunal o regional.

4. Amenazas adicionales a la inferencia

Una amenaza importante en este análisis es la confusión por variables omitidas. Es probable que existan factores no incluidos en los modelos que influyen tanto en la composición demográfica como en los resultados de salud, como el nivel de ingreso, acceso a atención médica, calidad de la infraestructura sanitaria o características ambientales.

La omisión de estas variables puede generar sesgos en los coeficientes estimados, produciendo asociaciones que no reflejan relaciones reales. En trabajos futuros, este problema podría abordarse incorporando más covariables relevantes, utilizando modelos con efectos fijos espaciales o aplicando técnicas que permitan controlar mejor la heterogeneidad entre comunas.

Part 5: Spatial Visualization of Model Output

Part 5.1 — Predicted-rate map

```
import geopandas as gpd
import matplotlib.pyplot as plt
import pandas as pd
import unicodedata


# 1. Base de datos

df_map = df_model.copy().reset_index()

df_map["pop_total"] = pd.to_numeric(df_map["pop_total"],
errors="coerce")
df_map["log_pop_total"] = np.log(df_map["pop_total"].replace(0,
np.nan))

model = nb_model_eno

df_map["pred_eno_total"] = model.predict(
    df_map,
    offset=df_map["log_pop_total"]
)

df_map["pred_eno_rate_per_10k"] = (
    df_map["pred_eno_total"] / df_map["pop_total"] * 10000
)

# 2. Shapefile
shp_path =
"/Users/ignaciorodriguezperez/Desktop/Preparacion_datos/comunas/comuna
s.shp"
comunas_gdf = gpd.read_file(shp_path)

name_col = "Comuna"

# 3. Limpieza robusta de nombres
def clean_name(x):
    if pd.isna(x):
        return None

    x = str(x).strip()

    # Arreglar caracteres mal codificados tipo MaipÃº, Ñuñoa,
Peñaflor, etc.
    try:
        x = x.encode("latin1").decode("utf-8")
    except:
```

```
        pass

    x = x.upper()

    # Quitar tildes
    x = unicodedata.normalize("NFKD", x).encode("ASCII",
"ignore").decode("utf-8")

    # Normalizar espacios
    x = " ".join(x.split())

    return x

comunas_gdf["nombre_clean"] = comunas_gdf[name_col].apply(clean_name)
df_map["nombre_clean"] = df_map["nombre_comuna"].apply(clean_name)

# 4. Merge por nombre limpio
map_gdf = comunas_gdf.merge(
    df_map,
    on="nombre_clean",
    how="inner"
)

print("Comunas del dataset:", df_map["nombre_clean"].nunique())
print("Comunas encontradas en mapa:",
map_gdf["nombre_clean"].nunique())

faltan_en_mapa = sorted(set(df_map["nombre_clean"]) -
set(map_gdf["nombre_clean"]))

print("\nComunas del dataset que no aparecen en shapefile:")
print(faltan_en_mapa)
print("Total faltantes:", len(faltan_en_mapa))

# 5. Choropleth
fig, ax = plt.subplots(figsize=(10, 9))

map_gdf.plot(
    column="pred_eno_rate_per_10k",
    cmap="OrRd",
    legend=True,
    edgecolor="black",
    linewidth=0.3,
    ax=ax,
    vmin=map_gdf["pred_eno_rate_per_10k"].quantile(0.05),
    vmax=map_gdf["pred_eno_rate_per_10k"].quantile(0.95)
)

ax.set_title(
    "Predicted ENO Notification Rate per 10,000 inhabitants",
```

```
    fontsize=14
)

ax.axis("off")
plt.tight_layout()
plt.show()
```

```
Comunas del dataset: 51
Comunas encontradas en mapa: 51

Comunas del dataset que no aparecen en shapefile:
[]
Total faltantes: 0
```

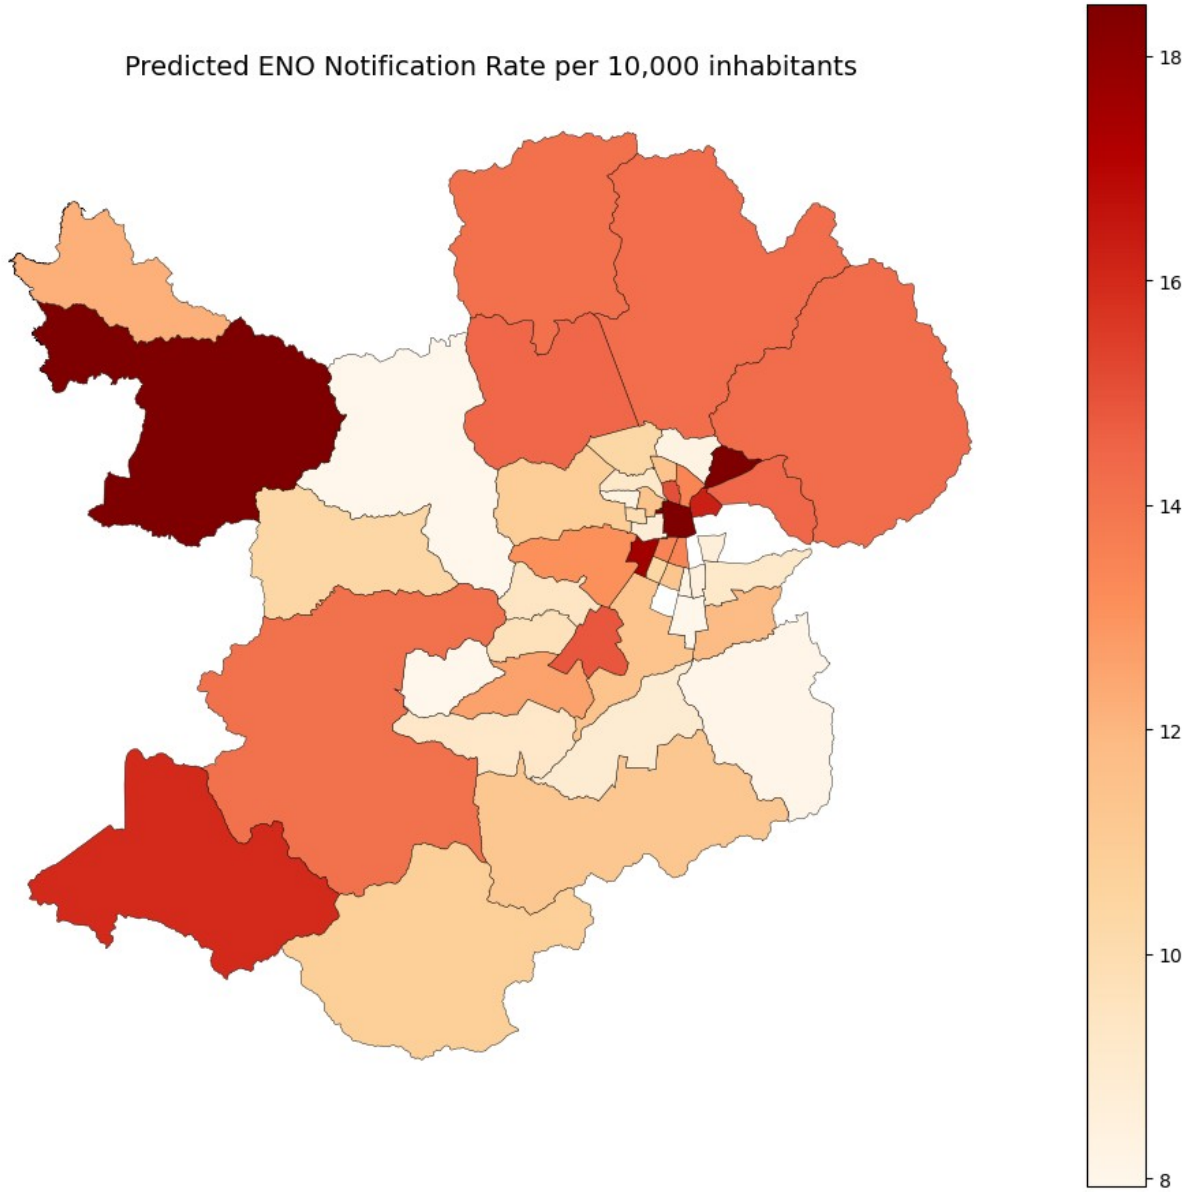

Se construyó un mapa coroplético utilizando la tasa predicha de notificaciones ENO por cada 10.000 habitantes, obtenida a partir del modelo Negative Binomial estimado en la Parte 2.

Para generar el mapa, se integró la base de datos modelada con un shapefile de comunas, realizando un proceso de limpieza y normalización de nombres que permitió un emparejamiento completo (51 de 51 comunas). Esto asegura que no se perdió información en la visualización.

Los resultados muestran una heterogeneidad espacial clara en las tasas predichas. Algunas comunas presentan niveles considerablemente más altos, lo que podría estar asociado a factores demográficos o estructurales capturados por las covariables del modelo.

Para mejorar la interpretabilidad visual, se ajustó la escala de colores utilizando percentiles, evitando que valores extremos distorsionen la representación del resto de las comunas.

Este tipo de visualización permite identificar patrones espaciales relevantes que pueden ser útiles para la planificación en salud pública, aunque no implica relaciones causales a nivel individual.

5.2 Residual map

```
# Copia de la base usada en 5.1
df_resid = df_map.copy()

# Observado y predicho
df_resid["observed_eno_total"] = df_resid["eno_total"]
df_resid["predicted_eno_total"] = df_resid["pred_eno_total"]

# Pearson residuals
# Para conteos: (observado - predicho) / sqrt(predicho)
df_resid["pearson_residual"] = (
    (df_resid["observed_eno_total"] - df_resid["predicted_eno_total"])
/
    np.sqrt(df_resid["predicted_eno_total"])
)

# Merge con shapefile usando nombre_clean ya creado
map_resid = comunas_gdf.merge(
    df_resid,
    on="nombre_clean",
    how="inner"
)

print("Comunas en mapa de residuos:", len(map_resid))

# Revisar extremos
top_positive = (
    df_resid
    .sort_values("pearson_residual", ascending=False)
    [["nombre_comuna", "pearson_residual"]]
    .head(5)
)
```

```python
top_negative = (
    df_resid
    .sort_values("pearson_residual", ascending=True)
    [["nombre_comuna", "pearson_residual"]]
    .head(5)
)

print("Top residuos positivos:")
display(top_positive)

print("Top residuos negativos:")
display(top_negative)

# Mapa de residuos
fig, ax = plt.subplots(figsize=(10, 9))

vmax = np.nanquantile(np.abs(map_resid["pearson_residual"]), 0.95)

map_resid.plot(
    column="pearson_residual",
    cmap="RdBu_r",
    legend=True,
    edgecolor="black",
    linewidth=0.3,
    ax=ax,
    vmin=-vmax,
    vmax=vmax
)

ax.set_title("Pearson Residuals of ENO Model", fontsize=14)
ax.axis("off")

plt.tight_layout()
plt.show()
```

```
Comunas en mapa de residuos: 51
Top residuos positivos:

   nombre_comuna  pearson_residual
2       Santiago       1601.278740
0     Valparaíso        240.297502
45     San Pedro        169.317262
32   Puente Alto        141.832474
26      Recoleta        122.870955

Top residuos negativos:

      nombre_comuna  pearson_residual
44      María Pinto          4.050731
42            Alhué          6.787944
```

```
39  Calera de Tango          7.526948
48    Isla de Maipo         13.109203
46        Talagante         22.219174
```

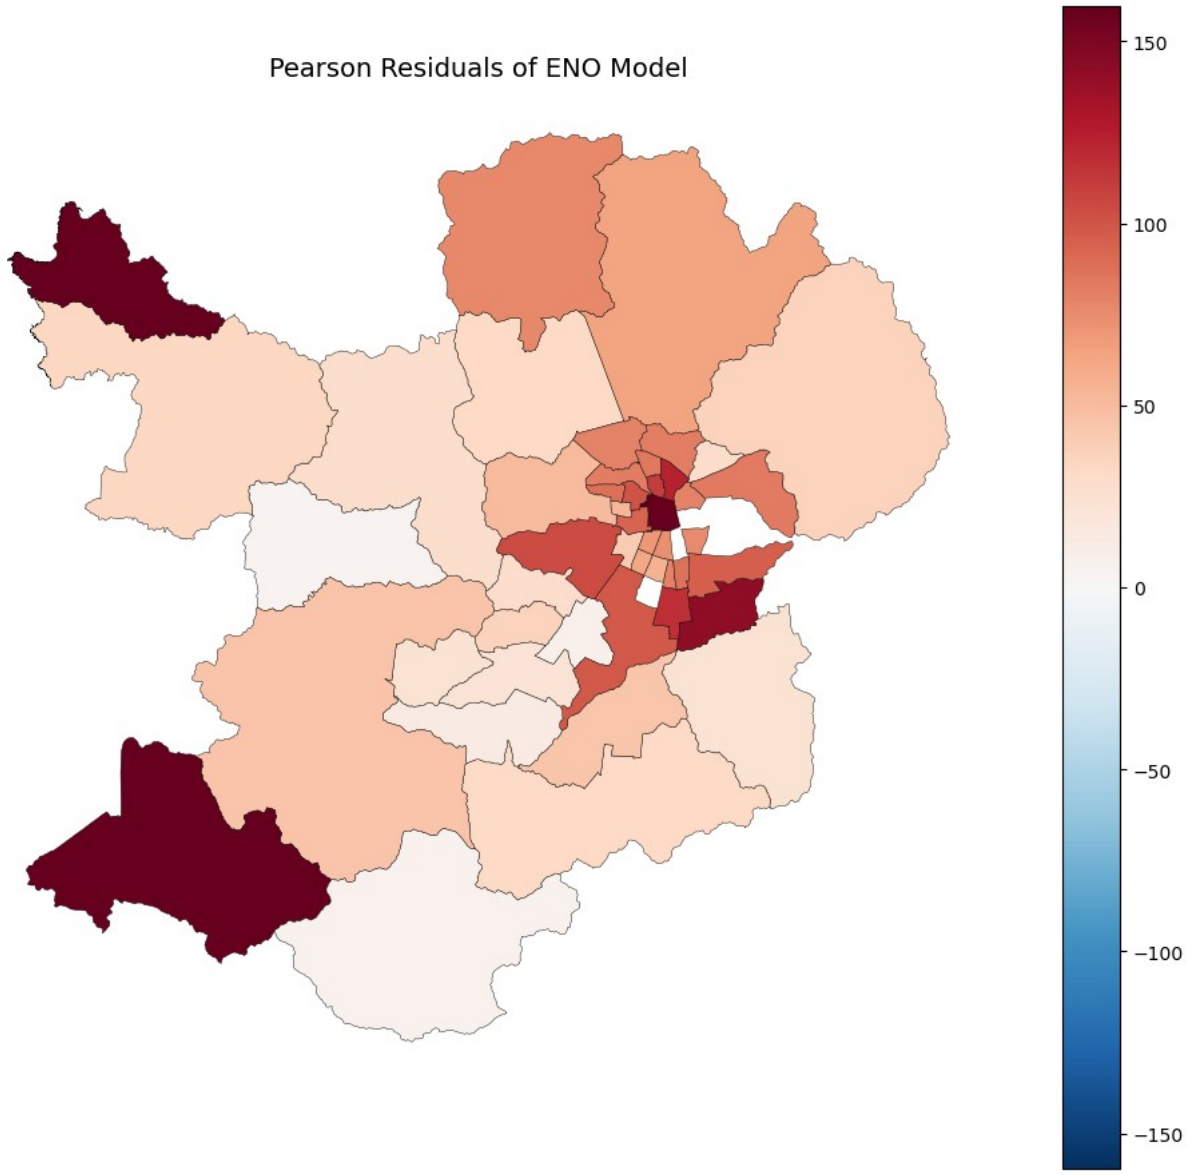

Se calcularon los residuos estandarizados de Pearson a partir del modelo binomial negativo y se representaron en un mapa coroplético utilizando una paleta divergente centrada en cero. Este tipo de visualización permite identificar comunas donde el modelo sobreestima o subestima las tasas de notificación ENO.

Las comunas con los mayores residuos positivos corresponden a Santiago, Valparaíso y San Pedro, destacando especialmente Santiago con un valor extremadamente alto. Esto indica que en estas comunas el número observado de notificaciones ENO es considerablemente mayor al predicho por el modelo, sugiriendo la presencia de factores no capturados, como mayor acceso

a servicios de salud, mayor densidad poblacional efectiva o diferencias en los sistemas de reporte.

Por otro lado, las comunas con los residuos más bajos (más cercanos a cero dentro del rango observado) incluyen María Pinto, Alhué y Calera de Tango. En estos casos, el modelo logra ajustarse de mejor manera a los datos observados, lo que sugiere que las variables incluidas capturan adecuadamente la dinámica de notificación ENO en estas comunas.

En conjunto, el patrón espacial de los residuos muestra que el modelo presenta mayores errores en comunas urbanas centrales, mientras que su desempeño es más consistente en comunas periféricas, lo que sugiere la necesidad de incorporar variables adicionales para mejorar el ajuste en zonas de alta complejidad urbana.

5.3 Coefficient plot

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

# Usar el modelo Negative Binomial de ENO estimado en Parte 2
model = nb_model_eno

# Extraer coeficientes e intervalos de confianza
params = model.params
conf = model.conf_int()
conf.columns = ["lower", "upper"]

# Crear tabla de coeficientes
coef_df = pd.DataFrame({
    "term": params.index,
    "coef": params.values,
    "lower": conf["lower"].values,
    "upper": conf["upper"].values,
    "p_value": model.pvalues.values
})

# Quitar intercepto y alpha si aparecen
coef_df = coef_df[~coef_df["term"].isin(["Intercept", "const",
"alpha"])].copy()

# Pasar a IRR
coef_df["IRR"] = np.exp(coef_df["coef"])
coef_df["IRR_lower"] = np.exp(coef_df["lower"])
coef_df["IRR_upper"] = np.exp(coef_df["upper"])

# Ordenar para visualización
coef_df = coef_df.sort_values("IRR")

display(coef_df)

# Plot
```

```python
fig, ax = plt.subplots(figsize=(8, 5))

y_pos = np.arange(len(coef_df))

ax.errorbar(
    coef_df["IRR"],
    y_pos,
    xerr=[
        coef_df["IRR"] - coef_df["IRR_lower"],
        coef_df["IRR_upper"] - coef_df["IRR"]
    ],
    fmt="o",
    capsize=4
)

# Línea nula IRR = 1
ax.axvline(1, linestyle="--", linewidth=1)

ax.set_yticks(y_pos)
ax.set_yticklabels(coef_df["term"])
ax.set_xscale("log")
ax.set_xlabel("Incidence Rate Ratio (IRR), log scale")
ax.set_title("Coefficient Plot - Negative Binomial ENO Model")

plt.tight_layout()
plt.show()
```

```
                term      coef     lower     upper   p_value       IRR
\
3    pct_unemployed -0.006683 -0.043170  0.029804  0.719604  0.993339

4  dependency_ratio  0.046566  0.012123  0.081008  0.008053  1.047667

1       pct_foreign  0.052284  0.012189  0.092380  0.010594  1.053675

2     schooling_gap  0.458113  0.196120  0.720107  0.000610  1.581088


   IRR_lower  IRR_upper
3   0.957749   1.030253
4   1.012197   1.084380
1   1.012264   1.096781
2   1.216673   2.054653
```

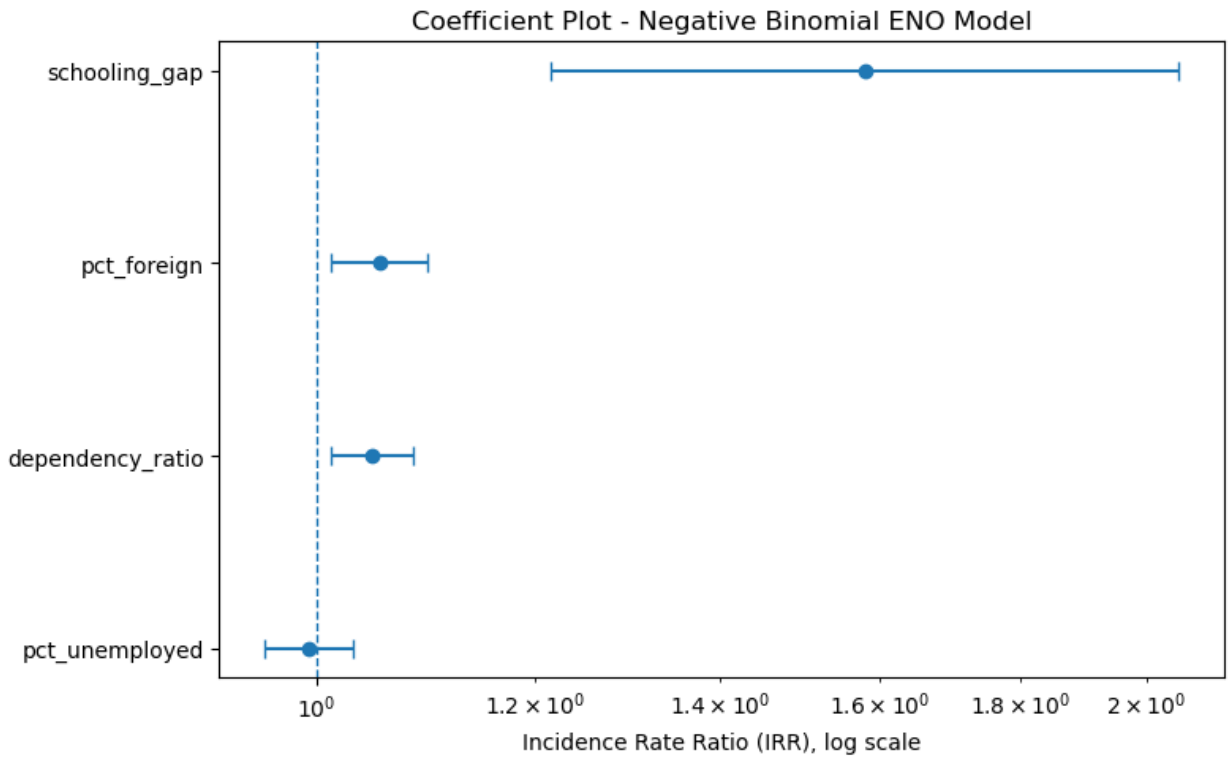

Se construyó un coefficient plot (forest plot) para el modelo Binomial Negativo, donde cada fila corresponde a una covariable incluida en el modelo. Para cada variable se muestra:

- El estimador puntual en términos de Incidence Rate Ratio (IRR)
- Su intervalo de confianza al 95%, representado como una barra horizontal
- El eje x en escala logarítmica, lo que permite interpretar multiplicadores de la tasa

La línea vertical en IRR = 1 representa la hipótesis nula (ausencia de efecto).

Interpretación de resultados

- schooling_gap presenta el mayor efecto, con un IRR considerablemente mayor a 1 y un intervalo de confianza completamente por encima de 1. Esto indica una asociación positiva fuerte y estadísticamente significativa con la tasa de notificaciones ENO.
- pct_foreign también muestra una asociación positiva significativa (IRR > 1), sugiriendo que comunas con mayor proporción de población extranjera presentan mayores tasas esperadas de notificación.
- dependency_ratio presenta un efecto positivo moderado, con un intervalo de confianza que no cruza el valor nulo, indicando significancia estadística.

- pct_unemployed tiene un IRR cercano a 1 y un intervalo de confianza que cruza la línea nula, lo que indica que no existe evidencia suficiente para afirmar una asociación significativa con la tasa de ENO.

En conjunto, el gráfico permite visualizar de manera clara la dirección, magnitud e incertidumbre de los efectos estimados, facilitando la comparación entre covariables y la identificación de aquellas con mayor relevancia en el modelo.

Part 6: Integrated Synthesis

1. Retrato demográfico y eje principal de variación

El retrato demográfico de la Región Metropolitana a nivel comunal muestra una alta heterogeneidad entre territorios, con un eje principal de variación claramente asociado a la composición socioeconómica y demográfica. Uno de los patrones más relevantes es la variación en la proporción de población extranjera (pct_foreign), la cual se concentra principalmente en comunas centrales y más urbanizadas como Santiago, Estación Central y Recoleta.

Estas comunas también presentan mayor densidad poblacional y, en varios casos, menores niveles promedio de escolaridad entre la población chilena, lo que refleja una gradiente socioeconómica marcada dentro de la región. En contraste, comunas periféricas como Alhué o María Pinto presentan menor densidad poblacional, menor proporción de población extranjera y estructuras etarias distintas, lo que se refleja en indicadores como el dependency_ratio.

En conjunto, el principal eje de variación puede interpretarse como una gradiente de urbanización, migración y condiciones socioeconómicas, que diferencia comunas centrales densas y diversas de comunas periféricas más homogéneas.

2. Relación entre el paisaje de salud y el eje demográfico

Este eje demográfico se relaciona de manera clara con el paisaje de salud observado en la Tarea 2. En general, las comunas con mayor proporción de población extranjera y mayor grado de urbanización presentan mayores tasas de notificación ENO por cada 10.000 habitantes. Este patrón se observa tanto en los análisis descriptivos como en los mapas de tasas predichas, donde las comunas centrales concentran valores más altos.

Sin embargo, esta relación no es perfecta. El análisis de residuos revela desajustes importantes. Por ejemplo, la comuna de Santiago presenta residuos positivos extremadamente altos, lo que indica que el modelo subestima fuertemente las notificaciones ENO en esa comuna incluso después de controlar por variables demográficas. Situaciones similares se observan en comunas como Valparaíso y Puente Alto.

Estos desajustes sugieren la existencia de factores adicionales no capturados por el modelo, como diferencias en acceso a servicios de salud, intensidad de reporte o patrones de movilidad de la población. Por otro lado, algunas comunas periféricas presentan residuos más pequeños, lo que indica que en estos casos las variables demográficas logran explicar de mejor manera los resultados de salud.

3. Aporte de los modelos integrados más allá de la correlación

Los modelos que integran información de múltiples datasets (Tarea 3) aportan información adicional relevante que no puede observarse a partir de correlaciones simples. Si bien una matriz de correlación podría sugerir una asociación positiva entre la proporción de población extranjera y las tasas ENO, el modelo Binomial Negativo permite evaluar esta relación controlando simultáneamente por otras variables.

En este contexto, se observa que pct_foreign mantiene una asociación positiva y estadísticamente significativa, incluso al considerar otras covariables. Además, el análisis de coeficientes muestra que la variable schooling_gap presenta el efecto más fuerte, con un IRR considerablemente mayor a 1, lo que sugiere que mayores diferencias en escolaridad entre población chilena y extranjera se asocian a mayores tasas de notificación ENO.

Asimismo, el dependency_ratio también presenta un efecto positivo significativo, indicando que comunas con mayor proporción de población dependiente pueden enfrentar mayores presiones sobre el sistema de salud. En contraste, la variable pct_unemployed no resulta estadísticamente significativa, lo que evidencia la importancia de utilizar modelos multivariados para distinguir relaciones reales de asociaciones espurias.

En conjunto, estos resultados muestran que el uso de modelos integrados permite identificar relaciones más robustas y comprender mejor los determinantes de las tasas ENO, aportando evidencia que no sería evidente al analizar cada dataset de forma aislada.